

Событийная память с адресуемыми источниками

Доставка свидетельств, темпоральные вопросы
и границы переноса в многосторонних диалогах

Ярослав Лихачев

Независимый исследователь

17 сентября 2026

Аннотация

Как сделать изменяющиеся факты длинного группового разговора доступными для поиска, не теряя их первоисточник? Мы предлагаем событийную память с адресуемыми источниками (Elem): каждое событие несёт самостоятельное поисковое описание, владельца точки зрения, субъект, время и неизменяемые пары *source ID* + *дословная цитата*. Память строится до чтения вопросов, события ранжируются вместе с исходными сообщениями, а найденное событие раскрывается обратно в первичные реплики.

Событийный индекс улучшает доставку размеченных свидетельств относительно сильного dense RAW. На 2400 вопросах EverMemBench он повышает precision gold-источников на 3,21 п.п. (95% ДИ [2,84; 3,59]) и recall на 0,64 п.п. ([0,48; 0,80]), возвращая в среднем меньше уникальных источников (9,47 против 10,00) и больше gold-попаданий (2,245 против 2,129). Направление сохраняется в каждом из пяти проектов, а на SocialMemBench, с памятью более раннего экстрактора, рост precision сохраняется при пересэмплировании разговорных сетей.

На exploratory-срезе Temporal Duration ($n = 300$) события достигают 19,3% accuracy против 14,0% у RAW и у HyDE при приближённо равном токен-бюджете и одинаковом хронологическом порядке: преимущество сохраняется после контролей объёма, порядка и расширения запроса. Срез выбран post hoc, и с поправкой на выбор категории сигнал не достигает подтверждающего статуса.

Полная система достигает 47,16% macro accuracy в adapter evaluation EverMemBench, выше опубликованных memory-систем с тем же answer model в описательном сравнении; собственный RAW получает 46,34%. В парных сравнениях средний прирост accuracy от событий и добавочный прирост от связывания в эпизоды не установлены, перенос между бенчмарками неоднороден. Работа показывает, что доставку источников и качество ответа нужно оценивать отдельно: событийный слой устойчиво улучшает первое, а связь со вторым остаётся открытым вопросом.

1 Введение

Разговорная память сталкивается с конфликтом двух целей. Для поиска удобно хранить самодостаточное описание: «Алексей сообщил, что больше не придёт на встречу». Для проверки нужен исходный материал: кто именно это написал, когда и какими словами. Если заменить историю summary, ответ становится доступнее, но исчезает граница между свидетельством и интерпретацией. Если хранить только сообщения, сохраняется доказательство, но поздний вопрос должен заново угадать все эллиптические, разнесённые и изменившиеся реплики.

Эта проблема особенно заметна в группе. Автор сообщения, владелец мнения и субъект высказывания могут быть тремя разными людьми. Одновременно идут несколько тем, а позиционная близость в потоке не означает принадлежность к одной линии разговора. Наконец, состояния эволюционируют: «буду на встрече» через неделю сменяется «уезжаю; на встречу не приду». Плоский профиль легко либо сохранит обе версии как действующие, либо сотрёт первую и лишит систему возможности объяснить изменение.

Мы предлагаем рассматривать derived memory не как новый источник истины, а как *индекс над свидетельствами*. В нашей реализации, Elem, событие содержит (i) текст, оптимизированный для semantic retrieval; (ii) тип, владельца точки зрения, субъект и наблюдаемое время; (iii) неизменяемый

ПОИСКОВАЯ АБСТРАКЦИЯ И ПРОВЕРЯЕМЫЙ ИСТОЧНИК



Рис. 1: Двухпредставная память: нормализованное событие служит семантическим мостом, а ответ строится с возвращёнными первичными репликами. Пример иллюстративный и не входит в бенчмарк.

набор source IDs и буквальных цитат. События конкурируют с raw turns в одном векторном top- k , а выбранные derived-документы раскрываются обратно в сообщения. Эпизоды — опциональная надстройка: они связывают пересмотр, подтверждение и дополнение, но не заменяют события и их источники.

Центральный вопрос работы: *помогает ли событийный индекс находить свидетельства, распределённые между участниками, сообщениями и моментами времени, сохраняя доступ к первоисточникам?* Вопросы о длительности и смене состояния — трудный частный случай этой задачи. Мы отвечаем в три шага: измеряем доставку размеченных источников на всех вопросах, проверяем temporal-преимущество контролями объёма, порядка и расширения запроса и определяем, что добавляют связывание в эпизоды и перенос на другие бенчмарки.

Вклады.

1. **Метод.** Событийный индекс с адресуемыми источниками: поисковое описание отделено от неизменяемой опоры, событие несёт владельца точки зрения, субъект, время и пары *source ID* + *дословная цитата*, а найденное событие раскрывается обратно в исходные сообщения.
2. **Улучшение доставки свидетельств.** На всех 2400 вопросах EverMemBench событийный индекс повышает precision и recall доставленных gold-источников относительно сильного dense RAW, возвращая меньше уникальных источников и больше gold-попаданий; направление сохраняется во всех пяти проектах и поддерживается на SocialMemBench.
3. **Раздельная оценка доставки и ответа.** Полная система достигает 47,16% macro accuracy в adapter evaluation EverMemBench; temporal-преимущество событий сохраняется после контролей бюджета, порядка и HyDE; парные сравнения определяют границы пользы: средний прирост accuracy от событий и от связывания в эпизоды не установлен, перенос между тремя бенчмарками неоднороден.

Память, прогоны и статистика запечатаны, а числа статьи пересчитываются офлайн (приложение H).

2 Связанные работы

Память агентов и разговорные задачи. Generative Agents соединяют поток опыта, retrieval и рефлексии [Park et al., 2023]; MemGPT управляет уровнями контекста [Packer et al., 2023]. Mem0 консолидирует факты [Chhikara et al., 2025], Zep/Graphiti использует временной граф [Rasmussen et al., 2025], A-MEM связывает заметки [Xu et al., 2025], Hindsight разделяет факты, опыт и beliefs [Latimer et al., 2025], HippoRAG реализует графовую ассоциацию [Gutiérrez et al., 2024]. В отличие от универсального memory manager, наша оценка сосредоточена на многостороннем разговоре со стабильными идентификаторами участников. LoCoMo и LongMemEval исследуют многосессионную память [Maharana et al., 2024, Wu et al., 2024]; EverMemBench, GroupMemBench и SocialMemBench добавляют соответственно длинные совместные проекты, reply-структуру и социальную атрибуцию [Hu et al.,

2026, Yang et al., 2026, Owolabi, 2026].

Ближайшие представления для поиска. Dense X Retrieval индексирует атомарные самостоятельные пропозиции [Chen et al., 2023]. RAPTOR строит иерархию summary; в collapsed-tree режиме исходные листья и производные узлы ранжируются совместно [Sarathi et al., 2024]. Самостоятельные утверждения и совместный пул raw и derived документов, таким образом, известны. Elem переносит их на меняющиеся разговорные состояния: событие явно разделяет автора, владельца мнения и субъекта, несёт наблюдаемое время и пофактовую пару *source ID* + *дословная цитата*, а адрес источника не зависит от поискового описания и версии эпизода. Экспериментально мы сравниваем эту конструкцию с собственным сильным RAW и разделяем вклад доставки источников, объёма контекста, порядка и episode linking; прямого сравнения с proposition retrieval или summary с той же provenance в работе нет (§10).

Расширение запроса и проверяемость. HyDE генерирует гипотетический документ для embedding запроса [Gao et al., 2023a]; событийная память нормализует корпус заранее. Мы сравниваем их на Temporal Duration с выравниванием бюджета и порядка. Как и работы по RAG и цитированию [Lewis et al., 2020, Gao et al., 2023b], мы отделяем поиск опоры от качества ответа: существующий указатель не доказывает семантическую корректность пересказа.

3 Формулировка задачи

Пусть $M = (m_1, \dots, m_n)$ — история одного bounded conversation space. Сообщение $m_i = (id_i, g_i, a_i, t_i, x_i)$ содержит пространство, автора, время и текст. Построитель B получает только M и создаёт память $\mathcal{D}$ до открытия QA. Для запроса q retrieval выбирает документы $R_k(q, \mathcal{D})$, после чего генератор отвечает по раскрытому контексту C_q .

Мы различаем три свойства:

1. **целостность указателя:** source ID существует, а цитата буквально содержится в нём;
2. **семантическая поддержка:** текст источника действительно влечёт derived-описание;
3. **правильность ответа:** генератор верно использовал доставленный контекст.

Механическая проверка гарантирует только первое. Второе требует entailment- или human-аудита, третье измеряется benchmark scoring.

4 Метод

4.1 Неизменяемое событие

Событие имеет вид

$$e = (z, o, s, k, r, \tau, P, L),$$

где z — самодостаточный index text, o — владелец точки зрения, s — субъект, k — тип события, r — temporal mode, τ — наблюдаемое время, P — evidence, L — локальный контекст. Evidence состоит из пар $(id_i, quote_i)$; время выводится из реальных timestamps источников.

Разделение o и s позволяет представить «А назвал Б ненадёжным» как мнение А о Б, а не как безусловный факт о Б; корректность этих полей определяется качеством извлечения. Типы охватывают состояние, мнение, решение, обязательство, отношение, исключение и категорию other. Разговорная реакция без долговременного содержания может не порождать события; действует cap не более двух событий на один turn.

Пример. Иллюстративный фрагмент одной рабочей сессии, не из бенчмарка:

10:02, Марина: «Релиз двигаем на пятницу — у Олега не закрыт платёжный модуль».

10:05, Олег: «Сделаю до вечера».

18:40, Олег: «Готово, можно катить».

Через неделю задан вопрос: «Кто задерживал релиз и закрыл ли он свою часть?» Ответ содержится в реплике 18:40, но в ней нет ни релиза, ни платёжного модуля, ни имени того, о ком идёт речь: связь с вопросом существует только через соседние сообщения. Схема допускает два события:

- e_1 : z = «Марина связала перенос релиза на пятницу с незакрытым платёжным модулем Олега»; o = Марина, s = Олег, τ = 10:02; P : (10:02, «у Олега не закрыт платёжный модуль»).
- e_2 : z = «Олег сообщил, что закрыл платёжный модуль»; o = Олег, s = платёжный модуль, τ = 18:40; P : (18:40, «Готово, можно катить»); сообщения 10:02 и 10:05 входят в L как контекст, разрешающий «готово».

Индексный текст e_2 делает короткое подтверждение доступным поиску по словам вопроса, а цитата указывает на исходную реплику. Здесь же видна граница этой гарантии. Цитата подтверждает, что реплика существует и написана Олегом в 18:40, но не подтверждает интерпретацию «закрыл платёжный модуль»: она опирается на сообщения из L . Генератору вместе с событием возвращаются только источники из P ; сообщения из L попадают в контекст, лишь если их независимо находит поиск. Поэтому поясняющую реплику 10:02 лучше включать в P , а проверка буквальности цитат этого не обеспечивает: это семантическая поддержка (свойство 2 в §3), а не целостность указателя. Поля выполняют разные роли: o отличает утверждение Марины об Олеге от собственного сообщения Олега, s задаёт, о ком или о чём факт, а τ отделяет состояние «не закрыт» от более позднего «закрыт». Пример иллюстрирует роль полей схемы; измеренные эффекты приведены в §7.1–7.4.

4.2 Query-independent extraction и валидация

История разделяется по benchmark-сессиям: в EverMemBench — день и группа; в GroupMemBench — канал/фаза с блоками до 40 сообщений. Forced structured output допускает пустой список. Затем детерминированный валидатор удаляет выдуманные IDs, отсутствующие цитаты, content-free значения и некорректные enum. Локальный context может помочь разрешить местоимение, но не становится evidence автоматически.

4.3 Опциональные версионные эпизоды

Эпизод $E_j = ((e_1, \rho_1), \dots, (e_t, \rho_t))$ — append-only линия, где $\rho \in \{\text{create, revise, reaffirm, augment}\}$. Для нового события кандидаты ищутся только внутри conversation network. Скор равен

$$S(e, E) = 0,6 \cos(\phi(z_e), \phi(A_E)) + 0,4 \cos(\phi(z_e), \phi(z_{last(E)})).$$

Здесь A_E — конкатенация последних пяти событий, $z_{last(E)}$ — последнее событие; ϕ — локальный MiniLM embedding для linking. Три лучших эпизода поступают LLM-resolver. При пустом пуле, невалидном выборе или confidence ниже 0,5 создаётся новый episode; это защитная ветвь, а не дополнительный поиск. Для retrieval ответов используется отдельный embedding benchmark adapter. Для индекса хранится hot-view последних пяти событий, но cold events и evidence не удаляются. Мы предполагаем, что false split обходится дешевле false merge: разделённые события всё ещё могут независимо попасть в retrieval, тогда как ошибочное слияние может приносить посторонние источники в последующие обращения; частоты обеих ошибок не измерялись.

4.4 Единый поиск и provenance expansion

Raw turn и derived document имеют общий интерфейс

$$d = (id, kind, index_text, render_text, source_ids).$$

Вектор вопроса сравнивается с одним пулом; top-10 может содержать оба типа. После ranking каждый event/episode раскрывается в уникальные raw turns. Генератор видит derived-текст как навигационную подсказку и датированные speaker-grounded источники как основание ответа.

Derived memory проходит тот же критерий релевантности, что и raw history; статические пользовательские профили не добавляются.

5 Экспериментальный протокол

5.1 Данные и условия

Benchmark	QA	пространства	Основная проверка
EverMemBench	2400	5 проектов	9 типов задач; temporal controls
SocialMemBench	1031	43 сети	социальная атрибуция, нормы, updates
GroupMemBench	745	4 домена	reply structure, implicit, multi-hop

Таблица 1: Используемые внешние наборы. Для GroupMemBench 102 первоначально пустых generation outputs восстановлены отдельным запечатанным amendment; исходный protocol result сохранён.

Основной paired baseline — сильный dense RAW, а не слабый keyword-only поиск. Условия EVENTS и EPISODES добавляют производные документы в тот же top-10. Для Temporal Duration дополнительно контролируются токен-бюджет и хронологический порядок; в контролях перестановки множество источников фиксировано внутри каждого условия, но не между RAW и EVENTS. HyDE генерирует гипотетический документ только для embedding запроса и возвращает те же raw documents. Все варианты используют одинаковые official answer/judge prompts внутри соответствующего benchmark adapter.

EverMemBench использует GPT-4.1-mini для ответа, Gemini-3-Flash-preview для open-answer judge, text-embedding-3-large для retrieval и gpt-4o-mini-2024-07-18 для построения памяти. Answer-и judge-модели, их промпты и точное скорирование multiple choice взяты из официального harness; провайдеры запинены (OpenAI и Google AI Studio соответственно) с отключёнными fallback — это согласует модели оценки, но не все остальные компоненты чужих систем. Ответы и judge EverMemBench используют temperature = 0. SocialMemBench следует GPT-4o-mini official-compatible harness. GroupMemBench использует GPT-5 официального прогона; версия модели у провайдера не была запинена датой, поэтому побайтовое воспроизведение этих чисел не гарантировано. Сравнения между бенчмарками не интерпретируются как сравнение моделей.



5.2 Метрики и статистика

Мы сообщаем micro accuracy, macro по официальным типам вопросов и парные разницы условий. Для вопроса q пусть U_q — множество уникальных раскрытых источников, G_q — gold anchors, опубликованные бенчмарком:

$$P_q = \frac{|U_q \cap G_q|}{|U_q|}, \quad R_q = \frac{|U_q \cap G_q|}{|G_q|}.$$

При пустом U_q precision равна нулю, при пустом G_q recall по scorer равна единице; в проверенных Ever-вопросах G_q непусто. В таблицах приведены *средние по вопросам отношения*, а не отношение суммарных попаданий к суммарному числу источников. Эти метрики измеряют доставку размеченной опоры, не entailment, достаточность контекста или правильность пользовательских цитат.

95% ДИ для Ever и Group получены парным question bootstrap; для переноса на Social дополнительно пересэмплируются 43 разговорные сети. Accuracy сравнивается exact McNemar. Question-level интервалы описывают исследованный набор: его вопросы не равнозначны независимым проектам. Поэтому для evidence мы также показываем эффект по каждому Ever-проекту и leave-one-project-out чувствительность (приложение D).

А · ПОСТРОЕНИЕ ПАМЯТИ ДО ЧТЕНИЯ ВОПРОСОВ**В · ОПЦИОНАЛЬНОЕ СВЯЗЫВАНИЕ · ОБРАБОТКА ПО ВРЕМЕНИ****С · ОБЩИЙ ИНДЕКС И ВОЗВРАТ К ПЕРВИЧНЫМ СООБЩЕНИЯМ**

ИНВАРИАНТ · описание может меняться; первичная история и адрес свидетельства сохраняются.

Рис. 2: Полная архитектура. Память строится query-independently и запечатывается до QA. В основном варианте raw turns и episodes ранжируются совместно; в абляции episodes заменяются отдельными events. Derived-hit всегда раскрывается в raw sources.

Temporal Duration выбран после просмотра полного разреза, поэтому его анализ обозначен как exploratory; поправка на выбор категории приведена в §7.2. Протоколы, revisions и запечатывание артефактов вынесены в приложение.

6 Результаты: уровень системы и парные сравнения

Здесь разделены два вопроса. Насколько сильна полная система в абсолютном выражении, показывает описательное сравнение с опубликованными строками (§6.1). Что добавляет именно событийная память, показывают только парные сравнения с нашим RAW на тех же вопросах (§6.2) и контроля §7. Первый ответ характеризует достигнутый уровень системы, второй — вклад событийного слоя.

6.1 Сравнение с опубликованными системами

EverMemBench. Полная система EPISODES достигает **47,16% macro**, а RAW — 46,34%. Наш adapter result выше значений, reported Hu et al. [2026] с тем же answer-backbone: MemOS 42,55%, Zep 39,97%, Mem0 37,09%, Full Context 37,44% и MemoBase 34,27%. Разница с лучшей опубликованной memory-системой составляет 4,61 п.п.

На Temporal наш EPISODES получает 20,00% при 6,33–18,00% у опубликованных memory rows. Профиль по категориям неоднороден: MemOS выше на Multi-hop, Mem0 — на Update.

Сравнение фиксирует достигнутый уровень полного adapter; чужие системы не перезапускались на одной инфраструктуре. Сильный собственный RAW (46,34%) показывает, что большую часть этого уровня обеспечивают retrieval и answer model, а добавочный вклад памяти измеряется парно в §6.2.




Рис. 3: Macro accuracy на девяти категориях EverMemBench с answer-backbone GPT-4.1-mini. Опубликованные результаты взяты из benchmark paper [Hu et al., 2026]; наши строки получены adapter evaluation поверх официального harness. Сравнение описательное: не официальный leaderboard submission и не парный тест против чужих систем.

Система	Macro	Multi-hop	Temporal	Update	Style
EPISODES (ours)	47,16	13,25	20,00	47,39	38,07
EVENTS (ours)	46,82	13,25	16,33	47,01	33,52
RAW (ours)	46,34	12,85	12,33	46,27	30,11
MemOS	42,55	18,88	15,67	45,15	28,98
Zep	39,97	8,03	13,00	43,66	26,70
Mem0	37,09	11,24	6,33	51,87	22,73
MemoBase	34,27	12,85	18,00	30,60	17,05

Таблица 2: Абсолютный уровень EverMemBench, accuracy в процентах; answer model GPT-4.1-mini. Чужие строки: таблица 4 в arXiv:2602.01313v3 [Hu et al., 2026]; наши строки: полные прогоны без token/order controls. Macro усредняет все девять типов, остальные столбцы показывают четыре диагностических среза. Между блоками нет парного статистического теста.

SocialMemBench. На SocialMemBench полная система достигает MeanQ .368 (EPISODES) и .358 (RAW): практически на уровне опубликованного full-context .369 и выше перечисленных benchmark memory rows (лучший Subject-Mem .321).

Сравнение показывает разные требования к памяти: adapter получает высокую атрибуцию (.863 у EPISODES), а theory-of-mind и восстановление смены состояния остаются трудными даже при сохранённых источниках. На групповых решениях EPISODES уступают нашему RAW (.691 против .716), поэтому высокий общий уровень отражает весь adapter, а не только linking.

GroupMemBench. У GroupMemBench внешние результаты также зависят от типа задачи (приложение B). Например, опубликованный Hindsight достигает 54,94% на Temporal, но 17,76% на Update; наш EPISODES — 36,42% и 23,36% соответственно. При этом опубликованный BM25 достигает 54,94% на Temporal и 25,23% на Update: сравнение только с тяжёлыми memory-системами скрыло бы сильную простую альтернативу.

6.2 Парные сравнения внутри наших условий

EverMemBench. На micro уровне EPISODES улучшают 49,46%→50,21%: +0,75 п.п., 95% ДИ [−0,5; +2,0], $p = .256$. EVENTS дают 49,83%: +0,38 п.п., ДИ [−0,8; +1,6], $p = .589$. Оба интервала включают ноль: средний прирост accuracy в парном сравнении не установлен.

Система	MeanQ	Атрибуция	Решения	ToM	Смена состояния
EPISODES (ours)	.368	.863	.691	.262	.259
RAW (ours)	.358	.825	.716	.251	.233
Subject-Mem	.321	.780	.610	.240	.220
SMG	.213	.440	.690	.110	.100
Graphiti	.178	.460	.610	.050	.070
LangMem	.162	.390	.560	.060	.090
Mem0	.143	.310	.570	.050	.070
Cognee	.120	.250	.590	.100	.010

Таблица 3: SocialMemBench: question-weighted scores (0–1), не binary accuracy. Все строки используют GPT-4o-mini. Чужие результаты: таблица 4 [Owolabi, 2026]; наши: frozen official-v1 harness. Столбцы соответствуют Q4/AP, Q2/GD, Q5/TM и Q8/TS. Сравнение с внешними строками описательное.

Условие	Micro	Macro	Evid. recall	Evid. precision
RAW	49,46	46,34	8,08	21,29
EVENTS	49,83	46,82	8,71	24,50
EPISODES	50,21	47,16	10,75	22,45

Таблица 4: EverMemBench, все 2400 QA, проценты. Макро — среднее по девяти официальным типам вопросов; микро — по отдельным QA.




Рис. 4: Парные разницы EPISODES–RAW внутри каждого набора с question- или network-bootstrap 95% ДИ. Показаны только парные разницы: метрика (accuracy против MeanQ), протоколы и answer-модели у трёх наборов различаются. Group приведён после targeted repair пустых генераций; его отдельно зарегистрированный temporal/update endpoint ($n = 150$ из 745) показан отдельной строкой. Ни один интервал не исключает ноль.

Перенос между бенчмарками. На SocialMemBench парная разница EPISODES–RAW составляет +0,010 MeanQ, network-bootstrap 95% ДИ $[-.008; +.028]$: средний выигрыш в MeanQ не установлен.

На уровне доставки Social поддерживает направление EverMemBench. Precision доставленных источников растёт относительно RAW у flat-памяти (+0,90 п.п., network-bootstrap 95% ДИ $[+0,66; +1,19]$), versioned (+0,86 п.п., $[+0,61; +1,16]$) и episodes (+0,34 п.п., $[+0,15; +0,54]$); все три интервала исключают ноль. Результат получен на другой структуре разговоров и с другой answer model. Схемы памяти не идентичны: flat и versioned построены более ранним экстрактором, а базовый evidence recall Social (67,5%) существенно выше, чем у Ever, поэтому абсолютные величины эффектов между наборами не сопоставимы.

На GroupMemBench перенос неоднороден. На заранее зарегистрированном Group primary (Finance+Technology, knowledge update+temporal, $n = 150$) после восстановления пустых ответов RAW достигает 37,3%, EPISODES — 33,3%: $\Delta = -4,0$ п.п., ДИ $[-9,3; +1,3]$; на всех 745 QA — 43,1% против 41,5%, $\Delta = -1,6$ п.п., ДИ $[-4,0; +0,8]$. Направление отрицательное и сохраняется после repair; интервалы включают ноль. Детали 102 восстановленных генераций и исходного protocol result приведены в приложении G.




Рис. 5: Доставка свидетельств и ассурасу. **А:** парная разница evidence precision EVENTS–RAW по девяти официальным категориям, все 2400 вопросов, question bootstrap 95% ДИ; знак положителен везде, интервал включает ноль только у Constraint. **В:** та же ось против сдвига ассурасу; звёздочкой отмечен post hoc discovery-срез. Категория с наибольшим приростом доставки (Single-hop, +8,28 п.п.) стоит у потолка ассурасу 89,7% и не выигрывает ничего. Точки описывают неоднородность категорий, а не причинную связь доставки и ответа.

7 Событийное представление: доставка и темпоральные ответы

Сначала рассмотрим прямое изменение найденных источников, затем — его связь с качеством ответа. Такой порядок оценивает поисковую надстройку отдельно от общего уровня answer model.

7.1 Доставка свидетельств: основной результат

Мы сравниваем парно, по каждому вопросу, долю доставленных gold-источников (recall) и их плотность в контексте (precision) на всех 2400 вопросах, без отбора среза.

Условие	Источников	Gold-попаданий	Evid. precision
RAW	10,00	2,129	21,29
EVENTS	9,47	2,245	24,50
EPISODES	12,38	2,795	22,45

Таблица 5: EverMemBench, все 2400 QA: сколько уникальных источников попало в контекст, сколько из них оказались gold anchors, и какая доля контекста была gold. В среднем у EVENTS меньше источников и больше gold-попаданий, чем у RAW.

EVENTS–RAW, парно: precision +3,21 п.п. (95% ДИ [+2,84; +3,59], 855 вопросов лучше против 255 хуже), recall +0,64 п.п. ([+0,48; +0,80]). Знак прироста precision положителен во всех девяти официальных категориях, ДИ исключает ноль в восьми из девяти (таблица 10). Эффект не держится на одном проекте: прирост положителен в каждом из пяти проектов EverMemBench, а при исключении любого проекта остаётся в пределах 3,11–3,39 п.п. (приложение D). Событийный индекс, таким образом, приводит в фиксированный top-10 больше размеченной опоры.

Рост precision не сводится к уменьшению числа возвращённых источников. Precision могла бы вырасти только потому, что источников возвращается меньше. Данные показывают другое: EVENTS возвращают в среднем 9,47 источника против 10,00 у RAW и ни на одном вопросе не больше, но находят больше gold-попаданий — 2,245 против 2,129 на вопрос, дельта +0,117 (ДИ [+0,083; +0,151]); в 449 вопросах gold-попаданий строго больше без увеличения числа источников. Событийный индекс улучшает отбор опоры, а не просто укорачивает список. По токенам контекст при этом длиннее: derived-текст событий даёт в среднем 1177 против 1054 токенов o200k_base (пересчёт офлайн




Рис. 6: Контроли представления, объёма и порядка на exploratory Temporal Duration. EVENTS chrono сохраняют наблюдаемое преимущество над RAW и HyDE при приближённом выравнивании токен-бюджета и одинаковом порядке; EPISODES не превосходят EVENTS. Интервалы — question bootstrap 95%.

по запечатанному retrieval), поэтому роль объёма в temporal-результате проверяется отдельным токен-контролем (§7.2). EPISODES ведут себя иначе: они повышают recall вместе с объёмом (+2,68 п.п. recall при +2,4 источника), а их precision растёт слабее (+1,16 п.п.).

Query-side расширение этого не воспроизводит. На Temporal Duration при приближённо равном бюджете и одинаковом порядке matched HyDE получает близкий recall — 20,7% против 19,7% у EVENTS (разница EVENTS–HyDE –1,01 п.п., ДИ [–2,20; +0,17]), но заметно более разреженный контекст: precision у EVENTS выше на +6,68 п.п. (ДИ [+5,06; +8,27]). Против token-matched RAW HyDE повышает precision на +1,18 п.п. и recall на +1,61 п.п.. Расширение запроса и нормализация корпуса дают разный профиль доставки: при близком recall событийный индекс доставляет более плотную опору. Доминирование EVENTS по обеим координатам не установлено: recall у них немного ниже, а незначимая разница не означает эквивалентности.

Почему низкий recall совместим с высокой ассурасу. Gold-разметка Ever содержит медианно 27 источников на вопрос (межквартильный диапазон 21–37; максимум 96), тогда как RAW возвращает десять. Это задаёт низкую полноту относительно всего reference set. В RAW 316 из 2400 вопросов получили правильный verdict без единого доставленного gold anchor; в EVENTS таких вопросов 312. Gold intersection и ассурасу измеряют разные свойства системы; достаточность свидетельств для ответа отдельно не оценивалась.

7.2 Temporal Duration: преимущество после контролей

В исходном разрезе Temporal Duration RAW достигает 12,3%, EPISODES — 20,0%. Но эпизоды раскрываются в несколько сообщений: в среднем 17,4 источника против десяти у RAW. Поэтому мы последовательно проверили расширение raw-контекста, хронологический порядок, отдельные события вместо linked episodes и HyDE на стороне запроса.

Token matching использует число токенов раскрытого EPISODES-контекста как целевой бюджет и выбирает ближайший префикс ranked-документов без обрезания сообщений; это выравнивание бюджета, не побайтовое равенство. HyDE matched ориентирован на EVENTS-контекст. Chrono-контроли меняют только порядок уже выбранных блоков, сохраняя их источники. Средние размеры chrono-контекстов: RAW 2458, EVENTS 2456, HyDE 2451 токен. Пер-вопросная абсолютная разница EVENTS и RAW имеет медиану 35 токенов (1,48%), 95-й перцентиль 97 (4,60%) и максимум 139 (11,46%). Полные отклонения и правила их расчёта приведены в приложении E.

При приближённо равном токен-бюджете и одинаковом порядке EVENTS достигают 19,3% про-

Условие	Accuracy	Evid. recall	Evid. precision
RAW top-10	12,3	12,7	29,6
HyDE-RAW top-10	12,0	14,1	32,4
RAW count-matched	13,3	16,6	25,1
RAW token-matched	12,3	19,1	21,5
RAW token-matched chrono	14,0	19,1	21,5
HyDE-RAW token-matched chrono	14,0	20,7	22,6
EVENTS token-matched	17,0	19,7	29,3
EVENTS token-matched chrono	19,3	19,7	29,3
EPISODES ranked	20,0	20,5	31,1
EPISODES chrono	18,3	20,5	31,1

Таблица 6: Temporal Duration, $n = 300$, проценты. Precision и recall — средние пер-вопросных отношений после раскрытия источников.

тив 14,0% у RAW: +5,33 п.п., 95% ДИ [+0,67; +10,0], номинальное $p = .0402$. Matched HyDE также получает 14,0%; разница EVENTS–HyDE составляет +5,33 п.п., ДИ [+0,33; +10,33], номинальное $p = .0479$ (37 выигрышей против 21 проигрыша). Направление положительно во всех пяти проектах. Вне Temporal Duration, на 2100 вопросах, EVENTS дают –0,14 п.п. (ДИ [–1,33; +1,10], $p = .877$): преимущество сосредоточено в этом срезе, а не распределено по всем задачам.

Преимущество сопровождается характерным профилем доставки. События сочетают recall расширенного RAW (19,7% против 19,1%) с precision RAW top-10 (29,3% против 29,6%), тогда как HyDE повышает recall до 20,7% при precision 22,6% и accuracy 14,0%. Этот профиль согласуется с temporal-преимуществом; связь доставки и ответа проверяется в §7.3.

Статус temporal-сигнала. Срез выбран post hoc из девяти категорий. С консервативной Bonferroni-поправкой номинальные $p = .0402$ и $.0479$ становятся примерно .36 и .43; при пяти проектах используемый двусторонний exact sign-flip тест не может достичь $p < .05$ (минимум .0625). Предварительная фиксация matched-HyDE endpoint охватывает анализ, но не выбор среза. Temporal-результат, таким образом, — содержательный exploratory-сигнал, устойчивый к контролям бюджета, порядка и HyDE, но не подтверждённый эффект.

7.3 Связь доставки источников с качеством ответа

До расчёта мы записали правило офлайновой проверки: вне Temporal Duration разделить вопросы по тому, доминируют ли EVENTS или RAW по recall и precision, и сравнить направление accuracy. В страте, где EVENTS доставляют строго лучшую опору ($n = 650$), accuracy меняется на +0,77 п.п. (ДИ [–1,85; +3,54]); при доминировании RAW ($n = 209$) — на –2,39 п.п. ([–6,70; +2,39]). Направления соответствуют гипотезе, но заранее записанный критерий подтверждения не выполнен (приложение F).

Этот результат разграничивает установленное и открытое. Улучшение доставки измеряется непосредственно и устойчиво; его перенос в accuracy на доступных выборках не подтверждён. Раздельная оценка двух эндпоинтов показывает, какую пользу событийный слой уже даёт и какую ещё предстоит установить. Проверка выполнена на ранее изученном наборе, не устанавливает причинного механизма и не исключает влияния доставки на ответ: интервал в страте с лучшей доставкой допускает и заметный положительный эффект.

7.4 Что дают эпизоды сверх событий

В симметричных контролях EPISODES chrono получают 18,3%, EVENTS chrono — 19,3%: разница –1,0 п.п., ДИ [–5,0; +3,33], $p = .755$. В ранее запечатанном сравнении ranked episodes (20,0%) и events chrono (19,3%) разница составляла +0,67 п.п., $p = .888$. Добавочный средний выигрыш linking в accuracy не установлен.

Связывание меняет профиль доставки (§7.1) и хранит инспектируемую хронологию пересмотров, подтверждений и дополнений с доступом к прежним свидетельствам. Для поиска в исследуемом сценарии отдельные события оказываются более простой основой: разделённые события независимо попадают в контекст через обычное ранжирование.

8 Эффективность и инженерные свойства

8.1 Стоимость и задержка

Полный EverMemBench эксперимент зарегистрировал 26 413 API calls и верхнюю оценку list-price \$8,88. Из них построение памяти gpt-4o-mini стоит \$4,76, embeddings — \$0,46, ответы — \$3,12, judge — \$0,55. Эти цифры относятся к исследовательскому прогону с кэшами и не равны production TCO.

В эту сумму входят оба условия, повторы и оценки ответов, а не только индексация EPISODES, поэтому для сопоставления с чужими системами ниже используется стоимость построения памяти на GroupMemBench. Сериализованный episode snapshot занимает 12,77 MB, полный operational run вместе с embedding-кэшем — около 2,2 GB.




Рис. 7: Описательный GroupMemBench efficiency landscape на общей выборке 606 QA по значениям benchmark paper и нашего adapter. Размер точки кодирует reported storage. Наши точки используют repaired amendment; определения стоимости и backend различаются, поэтому график описывает инженерный trade-off, а не контролируемое сравнение цены при равном качестве.

На этой общей выборке Hindsight достигает 40,4% при reported ingestion \$32,10/domain и 4,25 GB; HippoRAG — 33,3%, \$8,64 и 5,76 GB; наш RAW — 34,7%, \$0,23 и 0,37 GB; EPISODES — 32,3%, \$1,92 и 0,41 GB. Система экономична относительно тяжёлых структурных решений, но Hindsight точнее. Из-за разных harness-компонентов это контекст, а не контролируемая причинная оценка цены.

Adapter достигает ассурасу на уровне HippoRAG без крупного graph/database backend: по опубликованным величинам построение Hindsight дороже нашего EPISODES примерно в 16,7 раза, а storage больше в 10,4 раза; для HippoRAG эти отношения составляют 4,5 и 14,0. Это отношения reported затрат и объёмов, а не измерения потребления RAM на одинаковом workload.

Что известно о скорости. На 2400 вопросах EverMemBench локальное ранжирование занимает в среднем 11,59 мс у RAW и 13,70 мс у EPISODES: добавка 2,11 мс, около 18%. Соответствующие p95 — 12,70 и 15,04 мс; сеть и генерация не включены. Сопоставимого измерения end-to-end query latency чужих memoгу-систем в использованных benchmark-таблицах нет, поэтому скорость с другими системами не сравнивается; длительность полного прогона зависит также от API latency, числа

Система	Accuracy, %	Ingestion, \$/domain	Storage, GB
Hindsight	40,4	32,10	4,25
RAW (ours)	34,7	0,23	0,37
HippoRAG	33,3	8,64	5,76
EPISODES (ours)	32,3	1,92	0,41
A-Mem	29,2	26,13	6,60
MemGPT	19,1	0,43	0,69
Mem0	15,5	18,41	0,99
GraphRAG	12,2	12,51	3,00

Таблица 7: Явные значения для рис. 7. Accuracy — агрегат по пяти non-abstention типам задач GroupMemBench (606 QA): для опубликованных систем он пересчитан из процентов по типам (приложение B), для наших — посчитан по repaired results. Это сопоставление агрегатов, а не единый прогон всех систем. Ingestion cost и storage взяты из соответствующих benchmark reports. Наши accuracy пересчитаны после targeted repair; стоимость repair ответов не включена в ingestion. Backend, harness и определения storage различаются, поэтому сравнение является описательным.

workers, retries и rate limits.

8.2 Инженерный смысл

Построение памяти оплачивается до вопросов; поиск не вызывает linker повторно. Hot-view ограничивает размер индексируемого эпизода, а cold history сохраняет все evidence pointers. Поэтому поисковое описание можно исправлять, не удаляя первичную историю. Запечатывание входов и кэширование позволяют отделить изменение метода от повторного sampling; спецификация приведена в приложении.

9 Риски и возможные ошибки

Пропуск extraction. Если событие не создано, факт остаётся доступен только через RAW. Structured output ограничивает формат, но не гарантирует полноту извлечения.

Attribution и semantic overreach. Буквально существующая цитата может поддерживать только часть описания; пересказ может принять автора сообщения за владельца мнения. Поэтому 100% quote-validity означает целостность адреса, а не 100% корректных фактов.

False split и false merge. Свободные subject/facet формулировки могут раскалывать одну линию на несколько эпизодов; retrieval может пережить такой split, если обе записи независимо попадают в контекст. Ошибочное слияние может приносить нерелевантный контекст в последующие обращения. Консервативные решения resolver могут уменьшать ошибочные объединения ценой разрыва цепочек; частоты split и merge в работе не измерялись.

Context displacement. Derived hit занимает место в top- k и может вытеснять полезный raw turn. Это возможное объяснение нейтрального или отрицательного переноса, в частности на speaker-conditioned GroupMemBench, но не установленная причина: без gold-разметки источников Group его нельзя проверить напрямую.

10 Ограничения

Два главных пробела. Первый: в работе нет сравнения с обычным пересказом тех же сообщений, снабжённым теми же источниками и полями speaker/time. Поэтому улучшение доставки установлено

для событийного индекса относительно сырого поиска, но не для событийной схемы относительно более простого *derived*-представления. Второй: *temporal*-выигрыш найден на *post hoc* выбранном срезе, и все его контроли используют те же 300 вопросов; независимой проверки на новом наборе нет. Оба требуют отдельных экспериментов.

Что именно измерено. *Gold-source delivery* не означает достаточность контекста или использование опоры генератором. *Quote-validity* проверяет адрес и буквальную цитату, не *entailment derived claim*; независимый *human*-аудит событий не завершён. В *GroupMemBench* нет *gold source IDs* ни в одном из 745 QA, поэтому доставка источников на нём не измерялась.

Что ещё не разделено. Генератор получает и найденные сообщения, и *derived*-текст. Контроль с одинаковыми источниками, но без поискового описания подготовлен (B1), однако завершённых ответов и вердиктов не найдено. Следовательно, вклад выбора источников пока не отделён от интерпретационной подсказки генератору.

Границы переноса. Выводы относятся к данному экстрактору, бюджетам и *bounded conversation spaces*; более сильный *extractor*, веса *linking* и *cap* событий не аблированы. Опубликованные строки других систем, стоимость и *storage* сравниваются описательно; они не являются контролируемым *production TCO*.

11 Заключение

Событийная память с адресуемыми источниками разделяет *как искать* и *чем обосновывать*: самостоятельное описание события делает короткие и разнесённые реплики доступными *semantic retrieval*, а неизменяемая *provenance* возвращает исходное сообщение с автором и временем.

Главный результат работы — улучшение доставки размеченных источников. На *EverMemBench* событийный индекс повышает *precision gold*-источников на 3,21 п.п. и *recall* на 0,64 п.п., возвращая меньше уникальных источников и больше *gold*-попаданий; направление сохраняется во всех пяти проектах и поддерживается на *SocialMemBench*. На *Temporal Duration* события сохраняют преимущество в ассигасу (19,3% против 14,0% у RAW и HyDE) после контролей объёма, порядка и расширения запроса; это *exploratory*-сигнал, требующий независимой проверки.

Раздельная оценка доставки и ответа показывает границу установленного: средний прирост ассигасу от событий и добавочный средний прирост от связывания в эпизоды не установлены, перенос между бенчмарками неоднороден. Для исследуемого поискового сценария это даёт практический выбор: отдельные *EVENTS* — простая основа поискового слоя, улучшающая доставку источников, а *EPISODES* — инспектируемая история пересмотров, подтверждений и дополнений. Сильный RAW обеспечивает большую часть общего уровня системы, поэтому новые *derived*-слои стоит оценивать парно против него и сразу по двум эндпоинтам — доставке источников и качеству ответа.

Список литературы

- Tong Chen, Hongwei Wang, Sihao Chen, Wenhao Yu, Kaixin Ma, Xinran Zhao, Hongming Zhang, and Dong Yu. Dense X retrieval: What retrieval granularity should we use? *arXiv:2312.06648*, 2023. URL <https://arxiv.org/abs/2312.06648>.
- Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready ai agents with scalable long-term memory. *arXiv:2504.19413*, 2025. URL <https://arxiv.org/abs/2504.19413>.
- Luyu Gao, Xueguang Ma, Jimmy Lin, and Jamie Callan. Precise zero-shot dense retrieval without relevance labels. In *Proceedings of ACL*, 2023a. URL <https://aclanthology.org/2023.acl-long.99/>.
- Tianyu Gao, Howard Yen, Jiatong Yu, and Danqi Chen. Enabling large language models to generate text with citations. *arXiv:2305.14627*, 2023b. URL <https://arxiv.org/abs/2305.14627>.

- Bernal Jiménez Gutiérrez, Yiheng Shu, Yu Gu, Michihiro Yoon, et al. HippoRAG: Neurobiologically inspired long-term memory for large language models. *arXiv:2405.14831*, 2024. URL <https://arxiv.org/abs/2405.14831>.
- Chuanrui Hu, Tong Li, Xingze Gao, Hongda Chen, Yi Bai, Dannong Xu, Tianwei Lin, Xiaohong Li, Yunyun Han, Jian Pei, and Yafeng Deng. Evaluating long-horizon memory for multi-party collaborative dialogues. *arXiv:2602.01313v3*, 2026. URL <https://arxiv.org/abs/2602.01313v3>.
- Chris Latimer, Nicolò Boschi, Andrew Neeser, Chris Bartholomew, Gaurav Srivastava, Xuan Wang, and Naren Ramakrishnan. Hindsight is 20/20: Building agent memory that retains, recalls, and reflects. *arXiv:2512.12818*, 2025. URL <https://arxiv.org/abs/2512.12818>.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL <https://arxiv.org/abs/2005.11401>.
- Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of LLM agents. *arXiv:2402.17753*, 2024. URL <https://arxiv.org/abs/2402.17753>.
- Olukunle Owolabi. SocialMemBench: Are AI memory systems ready for social group settings? *arXiv:2605.17789*, 2026. URL <https://arxiv.org/abs/2605.17789v1>.
- Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. MemGPT: Towards LLMs as operating systems. *arXiv:2310.08560*, 2023. URL <https://arxiv.org/abs/2310.08560>.
- Joon Sung Park, Joseph C. O’Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative agents: Interactive simulacra of human behavior. *arXiv:2304.03442*, 2023. URL <https://arxiv.org/abs/2304.03442>.
- Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A temporal knowledge graph architecture for agent memory. *arXiv:2501.13956*, 2025. URL <https://arxiv.org/abs/2501.13956>.
- Parth Sarthi, Salman Abdullah, Aditi Tuli, Shubh Khanna, Anna Goldie, and Christopher D. Manning. RAPTOR: Recursive abstractive processing for tree-organized retrieval. In *International Conference on Learning Representations (ICLR)*, 2024. URL <https://arxiv.org/abs/2401.18059>.
- Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. LongMemEval: Benchmarking chat assistants on long-term interactive memory. *arXiv:2410.10813*, 2024. URL <https://arxiv.org/abs/2410.10813>.
- Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. A-MEM: Agentic memory for llm agents. *arXiv:2502.12110*, 2025. URL <https://arxiv.org/abs/2502.12110>.
- Jingbo Yang, Kwei-Herng Lai, Xiaowen Wang, Shiyu Chang, Yaar Harari, and Evgeniy Gabrilovich. GroupMemBench: Benchmarking LLM agent memory in multi-party conversations. *arXiv:2605.14498v1*, 2026. URL <https://arxiv.org/abs/2605.14498v1>.

А Полные разрезы EverMemBench

Тип	n	RAW	EVENTS	EPISODES
Constraint	402	79,9	79,1	79,6
Multi-hop	249	12,9	13,3	13,3
Proactivity	427	65,8	64,6	64,2
Single-hop	213	89,7	89,7	87,8
Skill	169	33,7	32,0	30,8
Style	176	30,1	33,5	38,1
Temporal Duration	300	12,3	16,3	20,0
Title	196	46,4	45,9	43,4
Update	268	46,3	47,0	47,4

Таблица 8: Аккуратность по всем официальным категориям, проценты. EVENTS здесь — полный experiment A без token/order controls.

В GroupMemBench: абсолютные результаты по задачам

Система	Multi-hop	Update	Ambiguity	Implicit	Temporal
BM25	40,11	25,23	14,15	40,82	54,94
Dense RAG	36,26	23,36	21,70	46,94	32,72
Hindsight	42,31	17,76	37,74	40,82	54,94
HippoRAG	39,56	27,10	30,19	42,86	29,63
A-Mem	35,16	22,43	26,42	46,94	23,46
MemGPT	22,53	17,76	20,75	28,57	12,42
Mem0	21,98	4,67	11,32	20,41	16,67
GraphRAG	12,09	14,02	19,81	14,29	5,56
RAW (ours, repaired)	37,91	28,04	25,47	48,98	37,04
EPISODES (ours, repaired)	34,07	23,36	24,53	48,98	36,42
n нашего среза	182	107	106	49	162

Таблица 9: GroupMemBench, аккуратность в процентах. Внешние строки: таблица 2 arXiv:2605.14498v1 [Yang et al., 2026]; Dense RAG использует text-embedding-3-large. Наши строки пересчитаны по repaired results. Наши знаменатели по пяти типам согласуются с опубликованными процентами; это не подтверждает побайтное совпадение question files или harness.

Сумма пяти знаменателей равна 606; на этих non-abstention задачах построен efficiency landscape в основном тексте. Агрегат считается как $A_{606} = \sum_t n_t a_t / \sum_t n_t$, где a_t — опубликованная аккуратность системы на типе t , а n_t — число вопросов этого типа в наших артефактах (182, 107, 106, 49 и 162 для Multi-hop, Update, Ambiguity, Implicit и Temporal). Почти во всех ячейках $n_t a_t$ даёт целое число верных ответов, что согласует наши знаменатели с опубликованными процентами; у MemGPT на Temporal (12,42%) целого числа нет, и количество округлено до ближайшего. Так, для Hindsight $A_{606} = 245/606 = 40,4\%$, для нашего RAW — $210/606 = 34,7\%$, для EPISODES — $196/606 = 32,3\%$. Совпадение знаменателей не доказывает побайтно одинаковый набор вопросов, поэтому это сопоставление non-abstention агрегатов, а не общий прогон. Значение 40,4% у Hindsight не сопоставимо с 41,5% нашего EPISODES на всех 745 QA: это разные множества вопросов. В опубликованной таблице с abstention средняя аккуратность Hindsight равна 46,01%, BM25 — 43,22%; у нас на всех 745 QA — 43,09% RAW и 41,48% EPISODES. Но abstention содержит 139 вопросов в наших артефактах против 109, согласующихся с опубликованными процентами, поэтому эти четыре общие цифры приводятся отдельно, без общего ранжирования.

Таблица показывает, почему одной общей аккуратности недостаточно: Hindsight сильнее на Multi-hop и Ambiguity, наш RAW высок на Update и Implicit, а BM25 остаётся сильным ориентиром для Temporal.

Различие Temporal GroupMemBench и Temporal Duration EverMemBench также существенно: первый набор проверяет порядок и относительные выражения времени, второй — длительность между границами событий. Межбенчмарковый разрыв процентов не является сам по себе показателем ухудшения модели.

С Доставка свидетельств по категориям

Тип	n	Δ precision	95% ДИ
Single-hop	213	+8,28	[+6,50; +10,12]
Temporal Duration	300	+7,51	[+5,92; +9,11]
Style	176	+6,31	[+4,82; +7,84]
Update	268	+3,24	[+2,12; +4,39]
Skill	169	+2,32	[+1,04; +3,73]
Multi-hop	249	+1,63	[+0,59; +2,67]
Title	196	+1,55	[+0,85; +2,30]
Proactivity	427	+1,13	[+0,77; +1,52]
Constraint	402	+0,30	[−0,07; +0,69]

Таблица 10: EVENTS–RAW, парная разница evidence precision по девяти официальным категориям EverMemBench, проценты и п.п. Знак положителен везде; ДИ исключает ноль в восьми категориях из девяти. Сравните с таблицей 8: категория с наибольшим приростом доставки (Single-hop) не показывает выигрыша accuracy; её исходный уровень уже 89,7%.

Д Офлайновая редакторская проверка

Ключевые micro/macro и evidence-агрегаты независимо сверены с пер-вопросными строками. Для всех 2400 Ever-вопросов gold source IDs восстановлены из официальных reference spans; пересечения с раскрытыми источниками точно совпали с сохранёнными precision/recall. Таблица ниже — дополнительная описательная проверка устойчивости направления, выполненная после экспериментов, не новый зарегистрированный endpoint.

Проект	n	Δ precision	Δ recall
01	488	+2,50	+0,50
02	471	+3,45	+0,73
03	467	+3,22	+0,51
04	481	+3,61	+0,75
05	493	+3,28	+0,70

Таблица 11: EVENTS–RAW по пяти проектам EverMemBench, п.п.

При исключении любого одного проекта средний прирост precision составляет от 3,11 до 3,39 п.п. Это чувствительность на данном наборе, не подтверждение переноса на новые проекты. Social-интервалы в основном тексте дополнительно пересчитаны network bootstrap: 10 000 выборок из 43 сетей с возвращением, пер-вопросная дельта с весом фактического размера сети, seed 20260917.

Распределение числа Ever gold anchors: минимум 4, медиана 27, межквартильный диапазон 21–37, среднее 30,12, максимум 96. Правильный verdict при нулевом gold intersection наблюдается в 316 RAW, 312 EVENTS и 305 EPISODES ответах. Эти случаи выделяют пределы reference-based метрики, но не являются самостоятельным аудитом достаточности или верности ответа.

При повторной генерации и оценке одного EPISODES-условия на 300 вопросах изменились 12 verdicts (по шесть в каждую сторону), а evidence-метрики совпали во всех вопросах. Равенство относится к фиксированному retrieval этого контроля, не к произвольной будущей конфигурации.

Дополнительный контроль RAW count-matched возвращает столько сообщений, сколько раскрывает EPISODES на том же вопросе: accuracy 13,3%, recall 16,6%, precision 25,1%. Он также не воспроиз-

водит наблюдаемый temporal-уровень событий. В RAW chrono relative исходные абсолютные временные метки заменены относительными при том же наборе источников: ассурасу 8,3%, evidence-метрики неизменны. Это отдельный контроль временного оформления, не контроль удаления derived-текста.

Проверка опубликована в исходниках статьи как `verify_editorial.py`; её отчёт `editorial_verification.json` содержит hashes прочитанных входов. Артефакты экспериментов не изменяются. Экстремальные Wilcoxon p прежнего черновика исключены: старый helper не усреднял ранги при совпадениях; размеры эффектов и bootstrap-интервалы от этого helper не зависят.

Е Точность выравнивания токен-бюджета

Сопоставлены сохранённые `context_tokens` по одинаковым 300 QA keys, без восстановления промптов или новых генераций. Счётчик использует `o200k_base`; учитывается раскрытый контекст с оформлением блоков, но без вопроса и общей инструкционной рамки. Для пары условий a, b отклонение равно $|T_a(q) - T_b(q)|$, относительное — $100|T_a(q) - T_b(q)|/T_b(q)$. Процентили считаются отдельно для абсолютных и относительных отклонений: процент в таблице не является отношением двух отдельно усреднённых величин.

Пара chrono-контекстов	Медиана	95-й перц.	Максимум	Медиана, %
RAW — EPISODES	25	56,1	83	0,99
EVENTS — EPISODES	26	73,1	137	1,08
HyDE — EVENTS	25	55,1	97	1,06
EVENTS — RAW	35	97,0	139	1,48

Таблица 12: Абсолютные пер-вопросные отклонения token matching, в токенах, кроме последнего столбца. Знаменатель относительного отклонения — второе условие пары; все контексты упорядочены хронологически.

Для ключевого сравнения EVENTS — RAW межквартильный диапазон абсолютной разницы составляет 16–58 токенов; 95-й перцентиль относительной разницы 4,60%, максимум 11,46%. Для EVENTS — HyDE соответствующие медиана, 95-й перцентиль и максимум равны 25, 55,1 и 97 токенам; относительные значения — 1,06%, 3,22% и 8,76%. Средние контексты RAW, EVENTS, HyDE и EPISODES составляют 2458,1; 2456,1; 2451,4 и 2459,7 токена. Matching сближает бюджеты, но не устраняет различие размера на каждом вопросе. Эти отклонения не являются отдельной абляцией остаточного объёма. Расчёт включён в `verify_editorial.py` и `editorial_verification.json`, раздел `token_matching`.

Ф Связь evidence и accuracy: протокол анализа

Протокол `research/FRONTIER_MECHANISM_PREDICTION_PROTOCOL.md` фиксирует до расчёта этого анализа три страты вне Temporal Duration: А — EVENTS не хуже по recall и precision и строго лучше хотя бы по одной координате; В — аналогично доминирует RAW; С — смешанный результат или равенство. Правило подтверждения требует положительной значимой ассурасу-дельты в А, отрицательного направления в В и интервала, содержащего ноль, в С. Основное условие А не выполнено. Небольшое число discordant пар (77, 23, 67) ограничивает мощность; ДИ допускают и полезный положительный эффект. Анализ не устанавливает причинный bottleneck.

Страта	n	Дасс	95% ДИ	выигр./проигр.	McNemar
А (события доминируют)	650	+0,77	[−1,85; +3,54]	41/36	.649
В (RAW доминирует)	209	−2,39	[−6,70; +2,39]	9/14	.405
С (смешанный)	1241	−0,24	[−1,53; +1,05]	32/35	.807

Таблица 13: Офлайновая проверка связи доставки и ответа на 2100 вопросах вне discovery-среза, EVENTS–RAW, проценты и п.п.

G GroupMemBench: восстановление пустых ответов

Исходный прогон имел 102 пустых ответа из 1490: 44 RAW и 58 EPISODES. Amendment повторяет только эти вызовы с теми же sealed prompts и повышенным output budget; все 102 восстановлены. Остальные 1388 ответов сохранены побайтно, source IDs неизменны. Исходные результаты не переписаны.

Срез	Версия	n	RAW	EPISODES	Δ [95% ДИ]
Primary	исходная	150	34,0	30,0	-4,0 [-9,3; 1,3]
Primary	repair	150	37,3	33,3	-4,0 [-9,3; 1,3]
Все QA	исходная	745	42,0	40,3	-1,7 [-4,3; 0,7]
Все QA	repair	745	43,1	41,5	-1,6 [-4,0; 0,8]

Таблица 14: GroupMemBench до и после repair, проценты и п.п. Primary: Finance+Technology, knowledge update+temporal.

Repair стоил \$2,69; около 94% output tokens пришлись на hidden reasoning. Один общий payload был вызван дважды при параллельном заполнении cache; финальные ответы совпали. Repair является post-protocol amendment, не официальной leaderboard submission.

Проверены все 745 официальных QA: каждый содержит идентификатор вопроса, его текст, эталонный ответ и идентификатор спрашивающего участника. Ни source IDs, ни evidence spans в этой версии questions нет. Нельзя объявить evidence recall/precision, восстановив gold из самого ответа без отдельной разметки. Гипотеза вытеснения полезных источников на Group остаётся непроверенной. Раскрытые IDs обоих условий сопоставимы и найдены в корпусе из 120 000 сообщений; недостаёт именно gold-множества.

Н Воспроизведение: модели, промпты и масштаб памяти

	EverMemBench	SocialMemBench	GroupMemBench
Сети / проекты	5	43	4
Сессии извлечения	3570	348	3153
Сообщения	51 023	7355	120 000
События после валидатора	16 859	639	21 407
Отклонено валидатором	4548	428	6822
Эпизоды	9298	449	10 801
Решения attach: NEW	9298	449	10 801
AUGMENT	5175	151	5586
REAFFIRM	1482	11	2331
REVISE	904	28	2689

Таблица 15: Масштаб построенной памяти. Каждое сохранённое событие получает ровно одно решение attach, поэтому сумма решений равна числу событий, а число NEW — числу эпизодов. Счётчики взяты из запечатанных episodes_meta.json и attach_decisions.jsonl.

Модели и настройки памяти. Извлечение событий и решения attach выполняет gpt-4o-mini-2024-07-18 при temperature = 0, max_tokens = 8192 и JSON-выводе. Сессия передаётся целиком, по строке на сообщение: [[turn_id]] [ANCHOR] время говорящий: текст. На одно сообщение — не более двух событий. Кандидаты для attach — три лучших эпизода по скору $S(e, E)$ на локальных эмбедингах paraphrase-multilingual-MiniLM-L12-v2; при confidence ниже 0,5 создаётся новый эпизод; hot view — пять последних событий. Retrieval ответов: text-embedding-3-large (EverMemBench, GroupMemBench) и text-embedding-3-small (SocialMemBench), cosine top-10.

Шаблоны документов. Индексный текст события: Viewpoint owner: <o>. Subject: <s>. <z>; у эпизода вместо *z* стоят тексты пяти последних событий через `||`. Генератор получает заголовок [DERIVED EVENT / owner=<o> / subject=<s>], текст события и по строке [SOURCE <id>] на каждый источник из *P*; сообщения из *L* в этот документ не входят.

Где промпты и как пересчитать. Промпт извлечения и промпт attach — функции `_event_extraction_prompt` и `_attach_prompt` в `reproduction/research/temporal_episode_prototype.py`; `adapters` бенчмарков лежат рядом. Все числа статьи пересчитываются офлайн, без ключей API:

```
python3 analysis/verify_results.py
python3 analysis/verify_evidence_endpoint.py
```

Повторные прогоны требуют ключей OpenAI и OpenRouter; команды по бенчмаркам перечислены в `REPRODUCE.md`, например `python3 -m research.evermembench_parallel_resume --all`.

I Точная спецификация хранения

Единица	Поля и назначение
RawTurn	ID, conversation network, speaker, timestamp, text; неизменяемый адрес.
MemoryEvent	ID, index text, type, viewpoint owner, subject, temporal mode, observed time, evidence, local context.
EventEvidence	Event ID, raw source ID, literal quote; проверяемая связь.
EpisodeEvent	Episode ID, Event ID, order, attach operation; append-only история.
SearchDocument	kind, index text, render text, source IDs; общий retrieval interface.

Таблица 16: Логическая схема не зависит от JSONL, SQLite или PostgreSQL backend.

J Артефакты и границы утверждений

Код, протоколы и конфигурации: <https://github.com/yaroslavlikh/temporal-episodes> (репозиторий закрыт до публикации). Что именно он распространяет, определяется лицензией каждого бенчмарка: пер-вопросные предсказания и вердикты для EverMemBench (данные под Apache 2.0) и SocialMemBench (CC BY 4.0), а для GroupMemBench, у которого лицензии нет, — только агрегаты и SHA-256 удержанных пер-вопросных файлов. Кэши моделей, эмбединги и сами корпуса не распространяются. Идентификаторы и хэши запечатанных прогонов перечислены ниже.

Основные immutable каталоги:

- `evermembench_temporal_episodes_official_v1_20260915_021550_MSK`;
- `final_sprint_A_events_full_v1_20260915_233142_MSK`;
- `final_sprint_B2_episodes_chrono_v1_20260915_232910_MSK`;
- `final_sprint_C_hyde_raw_v1_20260916_024144_MSK`;
- `final_sprint_C2_hyde_token_matched_v1_20260916_024306_MSK`;
- `socialmembench_temporal_episodes_official_harness_v1_20260912_122626_MSK`.

Дополнительный sealed amendment GroupMemBench хранится в `final_sprint_D_groupmembench_repair_v2` (1490 строк), SHA-256:

```
results_v2      41ae844eabb292f9d0c7edbeed0476981155340ac85c5ef197d2184fcbd0d4a5
predictions_v2 20f2c60180a58d37c63f96904896266c8ac5805f83d822d321a34926850c8a96
```

Каталог не копировался в отдельный frozen container; восемь исходных файлов проверены по manifest и не изменены. Использованные revisions: EverMemBench code `e10b3d52f0e4`, data `a6b210a32248`; GroupMemBench `e2682e01ff49`. Скрипт фигур хэширует входные summaries/reports. Публичное размещение кода не означает автоматического разрешения на перераспространение benchmark corpora.

Какой Social-прогон канонический. В артефактах присутствуют два SocialMemBench-пайплайна, и смешивать их нельзя. Канонический — `socialmembench_temporal_episodes_official_harness_v1: text-embedding-3-small`, единый cosine top-10 и общий answer/judge/packing; из него взяты все числа работы, а строки RAW/FLAT/VERSIONED в нём — неизменённые результаты замороженного прогона 2026-09-11. Второй, `socialmembench_temporal_episodes_full_v1`, — более ранний гибрид (локальная MiniLM, raw top-12 + episode top-12, бюджет 400 слов); его RAW даёт evidence recall 48,5% против 67,5% у канонического. Парное сравнение условия из одного прогона с RAW из другого даёт правдоподобные и полностью ложные числа; мы отмечаем это здесь, потому что оба каталога распространяются вместе.

Входы и воспроизведение. Сохранённые evidence effect sizes и question-bootstrap интервалы доступны в `research/figures/evidence_endpoint_results.json`. Скрипт `build_dissociation_figure.py` строит категориальный рисунок по этим значениям; `build_figures.py` фиксирует hashes остальных входов. Редакторская проверка использует отдельный отчёт и не переписывает результаты.