

Разрыв между доставкой свидетельств и качеством ответа

Событийная память с адресуемыми источниками в долгих многосторонних диалогах

Ярослав Лихачев

Независимый исследователь

16 сентября 2026

Аннотация

В долгих многосторонних разговорах полезное знание редко совпадает с одной самодостаточной репликой: состояния меняются, решения уточняются, а поздний вопрос формулируется иначе, чем исходное обсуждение. Сырые сообщения сохраняют доказательность, но плохо устраняют этот семантический разрыв; свободные summary улучшают доступ, но могут потерять автора, время и пофактовую связь с источником. Мы исследуем *событийную память с адресуемыми источниками* (Elem): каждое производное событие имеет отдельный текст для поиска и неизменяемые указатели на исходные реплики с автором, временем и дословной цитатой. События строятся до чтения вопросов, участвуют в одном ранжировании с raw-сообщениями и после retrieval раскрываются обратно в первичные свидетельства.

Что подтверждено. Событийный слой надёжно улучшает *доставку свидетельств*. На всех 2400 вопросах EverMemBench precision доставленных gold-источников растёт на +3, 21 п.п. (95% ДИ [+2, 84; +3, 59], $p < 10^{-59}$) при одновременном росте recall на +0, 64 п.п. ([+0, 48; +0, 80]). Это не размен: события доставляют *меньше* источников, чем сырой поиск (9,47 против 10,00, никогда не больше), и при этом находят *больше* золотых (+0, 117 на вопрос, [+0, 083; +0, 151]). Направление положительно во всех девяти официальных категориях. Эффект реплицируется на SocialMemBench (+0, 90 п.п. precision для flat-памяти, $p < 10^{-31}$) и доминирует query-side расширение: при статистически одинаковом recall события дают на +6, 68 п.п. ([+5, 06; +8, 27]) более плотное evidence, чем matched HyDE.

Что не подтверждено. Ни один из этих выигрышей не конвертируется в качество ответа. На 2400 вопросах micro ассигасу меняется на +0, 38 п.п. (ДИ [-0, 8; +1, 6]). Зарегистрированная конфирматорная проверка на 2100 вопросах вне discovery-среза связь не подтверждает: там, где события доставляют строго лучшие свидетельства ($n = 650$), прирост ассигасу составляет +0, 77 п.п. ($p = .649$). Единственный номинально значимый выигрыш в ассигасу получен на post hoc выбранном срезе Temporal Duration и не переживает Holm-поправку на девять категорий; endpoint с априорно зафиксированными срезом и анализом (Group primary, $n = 150$) отрицателен.

Вклад. Мы предъявляем *диссоциацию*: в многосторонней разговорной памяти с сильным dense raw-baseline производное представление измеримо улучшает то, что доезжает до генератора, и это не является связывающим ограничением качества ответа. Обе половины утверждения измерены на одних и тех же запечатанных прогонах, причём evidence-эндпоинт детерминирован (0 расхождений из 300 при стохастическом реране), тогда как ассигасу переворачивается на 4% вопросов. Практический вывод: адресуемость свидетельств обходится почти бесплатно (\$1,92 за домен ingestion против \$32,10 у Hindsight, 0,41 GB, +2 мс), но ожидать от неё прироста ассигасу на текущих бенчмарках не следует.

1 Введение

Разговорная память сталкивается с конфликтом двух целей. Для поиска удобно хранить самодостаточное описание: «Алексей отменил участие, потому что уезжает». Для проверки нужен исходный материал: кто именно это написал, когда и какими словами. Если заменить историю summary, ответ становится доступнее, но исчезает граница между свидетельством и интерпретацией. Если хранить только сообщения, сохраняется доказательство, но поздний вопрос должен заново угадать все эллиптические, разнесённые и изменившиеся реплики.

Эта проблема особенно заметна в группе. Автор сообщения, владелец мнения и субъект высказывания могут быть тремя разными людьми. Одновременно идут несколько тем, а позиционная близость в

потоке не означает принадлежность к одной линии разговора. Наконец, состояния эволюционируют: «буду на встрече» через неделю сменяется «уехал из города». Плоский профиль легко либо сохранит обе версии как действующие, либо сотрёт первую и лишит систему возможности объяснить изменение.

ПОЧЕМУ СЫРЫХ СООБЩЕНИЙ НЕДОСТАТОЧНО




Рис. 1: Двухпредставная память: нормализованное событие служит семантическим мостом, а ответ строится с возвращёнными первичными репликами. Пример иллюстративный и не входит в бенчмарк.

Мы предлагаем рассматривать *derived memory* не как новый источник истины, а как *индекс над свидетельствами*. В нашей реализации, *Elem*, событие содержит (i) текст, оптимизированный для *semantic retrieval*; (ii) тип, владельца точки зрения, субъект и наблюдаемое время; (iii) неизменяемый набор *source IDs* и буквальных цитат. События конкурируют с *raw turns* в одном векторном *top-k*, а выбранные *derived*-документы раскрываются обратно в сообщения. Эпизоды — опциональная надстройка: они связывают пересмотр, подтверждение и дополнение, но не заменяют события и их источники.

Работа отвечает на три вопроса:

1. конкурентоспособна ли полная система относительно опубликованных *memory*-систем в согласованном *evaluation harness*;
2. даёт ли событийное представление эффект сверх большего объёма контекста, порядка сообщений и сильного *raw retrieval*;
3. переносится ли эффект между разными типами *multi-party memory* задач и оправдывает ли *episode linking* свою дополнительную сложность.

Вклады.

1. Двухпредставная единица памяти, где поисковая абстракция отделена от неизменяемого *raw evidence*, а автор и время сохраняются на всём пути до ответа.
2. Query-independent построение и единый *retrieval* по гетерогенным единицам памяти с детерминированным *provenance expansion*.
3. Полная *evaluation* на *EverMemBench*, *SocialMemBench* и *GroupMemBench* с фиксацией стоимости, размера, задержки и замороженных артефактов.
4. Механистический набор контролей, отделяющий количество текста, хронологический порядок, *event representation* и *episode linking*, включая честный отрицательный результат для *linking*.

2 Связанные работы

Долговременная память агентов. *Generative Agents* вводят поток опыта, *retrieval* и рефлекссию [Park et al., 2023]; *MemGPT* управляет несколькими уровнями контекста [Packer et al., 2023]. *Mem0* извлекает и консолидирует устойчивые факты, а его *graph*-вариант добавляет отношения [Chhikara et al., 2025]. *Zep/Graphiti* хранит *temporally-aware knowledge graph* [Rasmussen et al., 2025]; *A-MEM* динамически организует заметки [Xu et al., 2025]; *Hindsight* разделяет факты, опыт, *summaries* и *beliefs*

[Latimer et al., 2025]. HippoRAG использует графовую ассоциацию и персонализированный PageRank [Gutiérrez et al., 2024].

Наша цель уже, чем построение универсальной памяти: bounded multi-party chat с идентифицируемыми участниками. Новизна не в самом факте использования LLM или вектора и не в совместном ранжировании raw и derived документов, которое частично превосхищено collapsed-tree режимом RAPTOR [Sarathi et al., 2024], а в совместной конструкции *retrieval representation + immutable evidence address* со speaker- и time-атрибуцией и в контролируемом анализе того, когда она полезна.

Бенчмарки и атрибуция. LoCoMo и LongMemEval оценивают многосессионное запоминание [Maharana et al., 2024, Wu et al., 2024]. EverMemBench добавляет длинные multi-party и multi-group проекты [Hu et al., 2026]; GroupMemBench контролирует reply-структуру, speaker conditioning и неявные связи [Yang et al., 2026]; SocialMemBench измеряет факты, нормы, исключения и attribution в социальных группах [Owolabi, 2026]. RAG и ALCE разделяют полезность поиска и качество цитирования [Lewis et al., 2020, Gao et al., 2023b]. Мы аналогично не считаем валидный source pointer доказательством истинности derived claim.

Производные единицы индексации. Ближайший к нам класс работ строит derived-представление над корпусом до запросов. Dense X Retrieval индексирует пропозиции — атомарные самодостаточные утверждения, извлечённые из пассажей, — и показывает, что такая гранулярность превосходит пассажи и предложения на open-domain QA [Chen et al., 2023]. RAPTOR рекурсивно кластеризует и суммаризирует чанки в дерево, а в основном режиме (collapsed tree) уплотняет его в один слой и ранжирует косинусом все узлы сразу — и исходные листья, и порождённые summary [Sarathi et al., 2024]; по их же замерам от 18,5% до 57% выданных узлов оказываются не листьями.

Скажем прямо: идея одного пула из raw и derived документов не нова и частично превосхищена collapsed tree. Наше отличие лежит не здесь, а в природе единицы. Обе работы — методы над документным корпусом: у их производных единиц нет автора и времени, а связь с источником имеет гранулярность пассажа или листа, но не пофактового адреса. RAPTOR сам сообщает, что около 4% его summary содержат небольшие галлюцинации, и его структура не позволяет вернуть конкретное утверждение к конкретной опоре. Для многосторонней переписки этого недостаточно: ответ обязан назвать, кто и когда это сказал, а владелец мнения может не совпадать ни с автором реплики, ни с её субъектом. Поэтому derived-текст у нас сопровождается неизменяемым набором пар (source ID, словная цитата), который проверяется валидатором, и отдельными полями владельца и субъекта.

Отличаются и выводы. Dense X сообщает о широком выигрыше мелкой производной единицы; на multi-party chat мы получаем узкий — события помогают там, где свидетельства разнесены во времени, и не помогают в среднем (§7). Правдоподобные причины различия — другой домен и заметно более сильный dense raw baseline, чем пассажный поиск по Википедии.

Что сравнивают представления. Query rewriting и HyDE могут уменьшать лексический разрыв на стороне вопроса [Gao et al., 2023a]; event memory делает это на стороне корпуса, один раз до QA, и сохраняет привязку к evidence. Мы сравниваем оба механизма на Temporal Duration: HyDE не меняет ассигасу относительно Raw ни в top-10, ни после выравнивания токен-бюджета и хронологического порядка.

3 Формулировка задачи

Пусть $M = (m_1, \dots, m_n)$ — история одного bounded conversation space. Сообщение $m_i = (id_i, g_i, a_i, t_i, x_i)$ содержит пространство, автора, время и текст. Построитель B получает только M и создаёт память $\mathcal{D}$ до открытия QA. Для запроса q retrieval выбирает документы $R_k(q, \mathcal{D})$, после чего генератор отвечает по раскрытому контексту C_q .

Мы различаем три свойства:

Подход	Derived	Версии	Raw prov.	Raw+mem pool	До QA
Full context / BM25	—	—	да	—	да
Mem0 / summaries	да	частично	зависит	обычно нет	да
Zep / Graphiti	да	да	зависит	нет	да
Hindsight	да	да	trace	нет	да
RAPTOR	да	—	лист	да	да
Dense X	да	—	пассаж	нет	да
Elem (ours)	да	optional	цитата	да	да

Таблица 1: Концептуальное, а не исчерпывающее сравнение. “Raw provenance” — гранулярность возврата к первоисточнику; конкретные реализации перечисленных систем могут различаться. RAPTOR в режиме collapsed tree ранжирует summary-узлы и исходные листья в одном пуле, поэтому совместный пул сам по себе не является нашим отличием.

1. **целостность указателя:** source ID существует, а цитата буквально содержится в нём;
2. **семантическая поддержка:** текст источника действительно влечёт derived-описание;
3. **правильность ответа:** генератор верно использовал доставленный контекст.

Механическая проверка гарантирует только первое. Второе требует entailment- или human-аудита, третье измеряется benchmark scoring.

4 Метод

4.1 Неизменяемое событие

Событие имеет вид

$$e = (z, o, s, k, r, \tau, P, L),$$

где z — самодостаточный index text, o — владелец точки зрения, s — субъект, k — тип события, r — temporal mode, τ — наблюдаемое время, P — evidence, L — локальный контекст. Evidence состоит из пар $(id_i, quote_i)$; время выводится из реальных timestamps источников.

Разделение o и s предотвращает простой attribution collapse: «А назвал Б ненадёжным» хранится как мнение А о Б, а не как безусловный факт о Б. Типы охватывают состояние, мнение, решение, объяснительство, отношение, исключение и устойчивый паттерн. Разговорная реакция без долговременного содержания может не порождать события; действует cap не более двух событий на один turn.

4.2 Query-independent extraction и валидация

История режется только по естественным границам benchmark-сессий: в EverMemBench — день и группа; в GroupMemBench — канал/фаза с блоками до 40 сообщений. Forced structured output допускает пустой список. Затем детерминированный валидатор удаляет выдуманные IDs, отсутствующие цитаты, content-free значения и некорректные enum. Локальный context может помочь разрешить местоимение, но не становится evidence автоматически.

4.3 Опциональные версионные эпизоды

Эпизод $E_j = ((e_1, \rho_1), \dots, (e_t, \rho_t))$ — append-only линия, где $\rho \in \{\text{create, revise, reaffirm, augment}\}$. Для нового события кандидаты ищутся только внутри conversation network. Скор равен

$$S(e, E) = 0.6 \cos(\phi(z_e), \phi(A_E)) + 0.4 \cos(\phi(z_e), \phi(z_{last(E)})).$$

Три лучших эпизода поступают LLM-resolver; при недостаточной уверенности создаётся новый episode. Для индекса хранится hot-view последних пяти событий, но cold events и evidence не удаляются. False split здесь дешевле false merge: разделённые события всё ещё могут независимо попасть в retrieval, а ошибочное слияние систематически приносит посторонние источники.



4.4 Единый поиск и provenance expansion

Raw turn и derived document имеют общий интерфейс

$$d = (id, kind, index_text, render_text, source_ids).$$

Вектор вопроса сравнивается с одним пулом; top-10 может содержать оба типа. После ranking каждый event/episode раскрывается в уникальные raw turns. Генератор видит derived-текст как навигационную подсказку и датированные speaker-grounded источники как основание ответа.

Это отличается от «показать все портреты»: derived memory фильтруется тем же критерием релевантности, что и raw history. Статические портреты и описание личного чата в экспериментах не используются.

A · QUERY-INDEPENDENT INGESTION**B · OPTIONAL TEMPORAL LINKING****C · UNIFIED RETRIEVAL + PROVENANCE EXPANSION**

ИНВАРИАНТ · derived representation помогает найти смысл; raw evidence остаётся адресуемым и неизменным.

Рис. 2: Полная архитектура. Память строится query-independently и запечатывается до QA. В основном варианте raw turns и episodes ранжируются совместно; в абляции episodes заменяются отдельными events. Derived-hit всегда раскрывается в raw sources.

5 Экспериментальный протокол

5.1 Данные и условия

Benchmark	QA	пространства	Основная проверка
EverMemBench	2400	5 проектов	9 типов задач; temporal controls
SocialMemBench	1031	43 сети	социальная атрибуция, нормы, updates
GroupMemBench	745	4 домена	reply structure, implicit, multi-hop

Таблица 2: Используемые внешние наборы. Для GroupMemBench 102 первоначально пустых generation outputs восстановлены отдельным запечатанным amendment; исходный protocol result сохранён.

Основной paired baseline — сильный dense Raw, а не слабый keyword-only поиск. Условия Events и Episodes добавляют производные документы в тот же top-10. Для Temporal Duration дополнительно фиксируются число токенов, множество раскрытых raw sources и хронологический порядок; HyDE генерирует гипотетический документ только для embedding запроса и возвращает те же raw documents. Все варианты используют одинаковые official answer/judge prompts внутри соответствующего benchmark adapter.

EverMemBench использует GPT-4.1-mini для ответа, Gemini-3-Flash-preview для open-answer judge, text-embedding-3-large для retrieval и gpt-4o-mini-2024-07-18 для построения памяти. Answer- и judge-модели, их промпты и точное скорирование multiple choice взяты из официального harness; провайдеры запинены (OpenAI и Google AI Studio соответственно) с отключёнными fallback — то есть наши строки и опубликованные отличаются не судейской моделью. Все вызовы идут при temperature = 0. SocialMemBench следует GPT-4o-mini official-compatible harness. GroupMemBench использует GPT-5 официального прогона; версия модели у провайдера не была запинена датой, поэтому побайтовое воспроизведение этих чисел не гарантировано. Сравнения между бенчмарками не интерпретируются как сравнение моделей.




Рис. 3: Macro accuracy на девяти категориях EverMemBench с answer-backbone GPT-4.1-mini. Опубликованные результаты взяты из benchmark paper [Hu et al., 2026]; наши строки получены adapter evaluation поверх официального harness. Это не официальный leaderboard submission и не paired significance test против чужих систем.

5.2 Метрики и статистика

Мы сообщаем micro accuracy, macro по типам вопросов, evidence recall/precision по пересечению раскрытых source IDs с gold anchors — выпущенными бенчмарком reference spans, то есть сообщениями, помеченными как опора ответа, — paired differences, question bootstrap 95% CI и exact McNemar. Для пяти Ever projects дополнительно считается cluster/sign-flip анализ. Evidence-метрики не являются entailment или качеством пользовательских цитат.

Память и входы сохраняются в JSONL/SQLite, запечатываются SHA-256 и переиспользуются между контролями. Temporal Duration был выбран после просмотра полного разреза и везде обозначается exploratory. Семейство множественных сравнений для механистического claim — девять официальных категорий EverMemBench; мы приводим для него Holm-поправку с $m = 9$ рядом с номинальными p (§7). Отдельно действует потолок мощности: при пяти project clusters минимальное достижимое двустороннее sign-flip значение равно $2/2^5 = .0625$, поэтому cluster-level подтверждение на этих данных недостижимо ни при каком исходе.

Два эндпоинта и их разрешающая способность. Мы сообщаем результаты на двух уровнях, и они различаются не важностью, а измеримостью. *Accuracy* проходит через генератор и judge; *evidence recall/precision* вычисляются механически из раскрытых source IDs и gold anchors и не зависят ни от того, ни от другого. Разница видна эмпирически: при повторном прогоне одного и того же условия на тех же 300 вопросах accuracy дала 12 перевёрнутых verdict-ов из 300 (4,0%; 6 в каждую сторону, чистый сдвиг ровно 0,00 п.п.), тогда как evidence-метрики совпали во всех 300 вопросах. Accuracy — зашумлённый прокси с потолками на лёгких категориях; evidence-эндпоинт детерминирован и разрешает эффекты, которые accuracy на доступных n не разрешает в принципе. Мы поэтому предъявляем evidence как основной измеряемый результат, а accuracy — как вопрос о том, конвертируется ли он (§7.3), и специально не подменяем одно другим.

6 Результаты: система в целом

6.1 EverMemBench: конкурентоспособность

Полная система Episodes достигает **47,16% macro**, а Raw — 46,34%. Наш adapter result выше значений, reported Hu et al. [2026] с тем же answer-backbone: MemOS 42,55%, Zep 39,97%, Mem0 37,09%, Full Context 37,44% и MemoBase 34,27%. Разница с лучшей опубликованной memogy-системой составляет

4,61 п.п.

Что это значит. Даже с несовершенным связыванием полная система демонстрирует высокий абсолютный уровень: наш adapter result выше всех GPT-4.1-mini memory rows, опубликованных Hu et al. [2026]. Это не controlled rerun чужих систем и не официальный leaderboard submission. Однако сильный собственный Raw уже превосходит их; поэтому нельзя приписывать все 4,61 п.п. именно event/episode memory.

Условие	Micro	Macro	Evid. recall	Evid. precision
Raw	49,46	46,34	8,08	21,29
Events	49,83	46,82	8,71	24,50
Episodes	50,21	47,16	10,75	22,45

Таблица 3: EverMemBench, все 2400 QA, проценты. Macro — среднее по девяти официальным типам вопросов; micro — по отдельным QA.

На micro уровне Episodes улучшают 49,46%→50,21%: +0,75 п.п., 95% ДИ $[-0,5; +2,0]$, $p = .256$. Events дают 49,83%: +0,38 п.п., ДИ $[-0,8; +1,6]$, $p = .589$. Следовательно, общий прирост внутри нашего paired comparison статистически не разрешён. Это не противоречит высокому абсолютному macro: вопросы «насколько сильна система?» и «какую долю эффекта добавляет компонент?» различны.

6.2 Перенос между бенчмарками




Рис. 4: Парные разницы Episodes—Raw внутри каждого набора с question- или network-bootstrap 95% ДИ. Абсолютные уровни не показаны намеренно: метрика (ассигасу против MeanQ), протоколы и answer-модели у трёх наборов различаются, и сравнивать их по высоте столбиков было бы некорректно. Group приведён после targeted repair пустых генераций; его отдельно зарегистрированный temporal/update endpoint ($n = 150$ из 745) показан отдельной строкой. Ни один интервал не исключает ноль.

SocialMemBench даёт MeanQ .358 для Raw и .368 для Episodes: +0,010, network-bootstrap 95% ДИ $[-.008; +.028]$. Результат практически совпадает с опубликованным full-context .369 и выше перечисленных benchmark memory rows (лучший Subject-Mem .321), но собственного значимого выигрыша нет.

По accuracy Social, таким образом, ничья. Но на уровне доставки свидетельств тот же прогон даёт разрешённый положительный эффект, и это единственный перенос между бенчмарками, который в работе вообще удалось установить. Парно по 1031 вопросу против Raw: flat-память +0,90 п.п. precision (ДИ $[+0,70; +1,11]$, $p < 10^{-31}$), versioned +0,86 п.п. ($[+0,65; +1,06]$), episodes +0,34 п.п. ($[+0,17; +0,51]$) при +0,99 п.п. recall ($[+0,16; +1,82]$). Величина заметно меньше, чем на Ever (+3,21 п.п.), и причина прозрачна: базовый evidence recall на Social равен 67,5% против 8,1% на Ever, то есть улучшать почти нечего. Направление, однако, воспроизводится на втором наборе, на другой модели и другом harness.

На pre-registered Group primary (Finance+Technology, knowledge update+temporal, $n = 150$) исходный protocol result был .340→.300. Targeted amendment повторил только 102 пустые генерации с теми

же sealed prompts и большим output budget; 102/102 восстановлены, остальные 1388 ответов не изменены. После repair Raw достигает .373, Episodes .333: дельта остаётся $-4,0$ п.п., ДИ $[-9, 3; +1, 3]$, $p = .210$. На всех 745 QA результат $.431 \rightarrow .415$, $-1,6$ п.п., ДИ $[-4, 0; +0, 8]$, $p = .246$. Следовательно, отрицательное направление не является артефактом пустых outputs. Repair стоил \$2,69; 94% его output tokens пришлось на hidden reasoning, что подтверждает причину исходного сбоя.

Существенно, что здесь априорно зафиксированы и срез, и анализ: домены Finance+Technology, типы knowledge update+temporal, $n = 150$ и статистика записаны в протокол до прогона. В отличие от temporal-эффекта (§7), где предварительная фиксация покрывает только endpoint, но не выбор среза, этот результат защищён от selection с обеих сторон — и он отрицателен. Асимметрия статуса между отрицательным и положительным результатами работы направлена не в нашу пользу, и мы считаем нужным назвать её прямо.

Граница обобщения. Метод не является универсальной заменой raw retrieval. На Social он в среднем нейтрален; на Group текущая версия может вытеснять полезные speaker-conditioned raw turns даже после repair. Этот отрицательный перенос — часть результата, а не скрытая неудача.

7 Событийное представление: что оно меняет и что нет

Этот раздел разделён по эндпоинтам. Сначала мы показываем эффект, который измеряется напрямую и подтверждается на всём наборе: события меняют то, какие свидетельства доезжают до генератора (§7.1). Затем — где и как это отражается на ассигасу (§7.2), и, наконец, зарегистрированную проверку того, связаны ли эти две вещи вообще (§7.3). Забегая вперёд: первое подтверждено, третье — нет.

7.1 Доставка свидетельств: подтверждённый эффект


Мы сравниваем парно, по каждому вопросу, долю доставленных gold-источников (recall) и их плотность в контексте (precision) на всех 2400 вопросах — без отбора среза.

Условие	Источников	Gold-попаданий	Evid. precision
Raw	10,00	2,129	21,29
Events	9,47	2,245	24,50
Episodes	12,38	2,795	22,45

Таблица 4: EverMemBench, все 2400 QA: сколько уникальных источников попало в контекст, сколько из них оказались gold anchors, и какая доля контекста была gold. Events доминируют Raw по обеим координатам сразу.

Events—Raw, парно: precision $+3,21$ п.п. (95% ДИ $[+2, 84; +3, 59]$, Wilcoxon $p = 2,9 \cdot 10^{-60}$, 855 вопросов лучше против 255 хуже), recall $+0,64$ п.п. ($[+0, 48; +0, 80]$, $p = 4,6 \cdot 10^{-13}$). Знак положителен во всех девяти официальных категориях, а ДИ исключает ноль в восьми из девяти (приложение, таблица 9).

Это не механический артефакт объёма. Precision могла бы вырасти сама собой, если бы события просто доставляли меньше текста. Проверка даёт обратное: Events доставляют меньше источников, чем Raw (9,47 против 10,00), и *никогда* не больше — при этом находят больше золотых: 2,245 против 2,129 попаданий на вопрос, дельта $+0,117$ (ДИ $[+0, 083; +0, 151]$). Меньше контекста, больше свидетельств — доминирование, а не размен; в 449 вопросах оно строгое. Episodes ведут себя иначе: они покупают recall объёмом ($+2,68$ п.п. recall при $+2,4$ источника), и их precision растёт слабее ($+1,16$ п.п.). Это первое место в работе, где связывание и отдельные события различаются измеримо, — но различаются они ценой, а не пользой для ответа (§7.4).



Слева: парная разница по 2400 вопросам, question bootstrap 95% ДИ; серый — единственная категория, чей интервал накрывает ноль.
Справа: та же ось X против сдвига accuracy. Категория с наибольшим приростом доставки (Single-hop) стоит у потолка accuracy и не выигрывает.

Рис. 5: Диссоциация. **А:** парная разница evidence precision Events—Raw по девяти официальным категориям, все 2400 вопросов, question bootstrap 95% ДИ; знак положителен везде, интервал накрывает ноль только у Constraint. **В:** та же ось против сдвига accuracy; звёздочкой отмечен post hoc discovery-срез. Категория с наибольшим приростом доставки (Single-hop, +8, 28 п.п.) стоит у потолка accuracy 89,7% и не выигрывает ничего. Знак категориальной корреляции зависит от выбора evidence-метрики и при $n = 9$ не разрешается ни в одну сторону (§7.3); вывод работы опирается на стратифицированный тест на 2100 вопросах, а не на эти девять точек.

Query-side расширение этого не воспроизводит. Matched HyDE на Temporal Duration при выровненных бюджете и порядке даёт статистически неотличимый от Events recall (−1,01 п.п., ДИ [−2, 20; +0, 17]), но заметно более разреженный контекст: Events—HyDE по precision составляет +6,68 п.п. (ДИ [+5, 06; +8, 27], $p = 9,3 \cdot 10^{-16}$). HyDE сам по себе бесполезен — против token-matched Raw он даёт +1,18 п.п. precision и +1,61 п.п. recall, — он доминируется. Расширение на стороне запроса и нормализация на стороне корпуса двигают разные координаты.

Что установлено. Производный слой улучшает доставку свидетельств надёжно, на всём наборе, во всех категориях, с репликацией на втором бенчмарке и доминированием над query-side расширением. Это измерено детерминированной метрикой, не зависящей ни от генератора, ни от judge, ни от выбора среза. *Останется ли этот выигрыш полезным* — отдельный вопрос, и ответ на него отрицательный (§7.3).

7.2 Ассурасу: где эффект виден и почему это слабое место

Мы разбираем Temporal Duration как срез с наибольшим *относительным* приростом полного Ever-разреза: Raw 12,3%, Episodes 20,0%, то есть +7,7 п.п. и +63% к базе (таблица 8). В абсолютных пунктах немного больший сдвиг даёт Style (30,1% → 38,1%, +8,0 п.п.), но при втрое более высокой базе и без гипотезы о механизме; для Events без controls Temporal Duration крупнейший и в абсолютных пунктах (+4,0 п.п. против +3,4 п.п. у Style). Прирост на Style мы не объясняем и не включаем в claims работы (§10). Сам выбор среза остаётся post hoc. Но derived-documents раскрываются в несколько сообщений, поэтому генератор видит в среднем 17,4 источника вместо 10. Чтобы отделить представление от объёма, мы дали Raw тот же токен-бюджет; затем отдельно выравнивали хронологический порядок и заменили linked episodes на независимые events. Matched HyDE-контроль проверяет, может ли тот же эффект дать query-side expansion без построения event memory.

При одинаковых токен-бюджете и порядке Events достигают 19,3% против 14,0% у Raw: +5,33 п.п., 95% ДИ [+0, 67; +10, 0], номинальное $p = .0402$. Matched HyDE также даёт 14,0%; разница Events—HyDE составляет +5,33 п.п., ДИ [+0, 33; +10, 33], номинальное $p = .0479$ (37 выигрышей против 21 проигрыша). Направление положительно во всех пяти проектах, но при пяти кластерах




Рис. 6: Механистические контроли на exploratory Temporal Duration. EVENTS chrono сохраняют преимущество над RAW и HyDE при равном бюджете и порядке; EPISODES не превосходят EVENTS. Интервалы — question bootstrap 95%.

Условие	Accuracy	Evid. recall	Evid. precision
RAW top-10	12,3	12,7	29,6
HyDE-RAW top-10	12,0	14,1	32,4
RAW token-matched	12,3	19,1	21,5
RAW token-matched chrono	14,0	19,1	21,5
HyDE-RAW token-matched chrono	14,0	20,7	22,6
EVENTS token-matched	17,0	19,7	29,3
EVENTS token-matched chrono	19,3	19,7	29,3
EPISODES ranked	20,0	20,5	31,1
EPISODES chrono	18,3	20,5	31,1

Таблица 5: Temporal Duration, $n = 300$, проценты.

минимальный достижимый sign-flip $p = .0625$. На всех 2100 вопросах вне Temporal Duration Events дают $-0,14$ п.п., ДИ $[-1, 33; +1, 10]$, $p = .877$. Эффект не объясняется простым «derived memory везде лучше»; он концентрируется там, где нужно найти разнесённые временные границы.

Механистическая картина не сводится к одной retrieval-метрике. Raw top-10 уже имеет precision раскрытых gold-источников 29,6% — не ниже, чем у Events (29,3%), — но при recall 12,7% даёт лишь 12,3% ассурасу. Чтобы поднять recall, сырому поиску приходится расширять окно: token-matched Raw доходит до 19,1% recall, precision падает до 21,5%, а ассурасу растёт только до 14,0%. HyDE смещает ту же кривую ещё дальше в recall (20,7%) при precision 22,6% — и ассурасу не меняется вовсе. Events держат обе координаты одновременно: recall 19,7% на уровне token-matched Raw и precision 29,3% на уровне Raw top-10, чему и соответствуют 19,3%.

На этом срезе события удерживают обе координаты сразу, тогда как сырому поиску они даются по очереди: два условия с почти одинаковым recall (19,1% и 19,7%) дают 14,0% и 19,3%, а два условия с почти одинаковой precision (29,6% и 29,3%) — 12,3% и 19,3%. Сюда же укладывается HyDE: он двигает только recall и не воспроизводит event gain.

Напрашивается объяснение — «ассурасу следует за recall–precision фронтиром доставленных свидетельств». Мы его проверили и не подтвердили (§7.3); само объяснение остаётся описанием четырёх строк таблицы 5, а не механизмом. Однако это всё ещё post-hoc discovery slice на пяти project clusters; project-level sign-flip $p = .1875$, а 288/300 verdicts совпали в stochastic rerun.

Поправка на множественность. Temporal Duration выбран из девяти официальных категорий после просмотра полного разреза, поэтому семейство равно $m = 9$. Первый шаг Holm сравнивает наименьшее p семейства с $\alpha/9 = .0056$; наши .0402 и .0479 его превышают, так что процедура останавливается

и ни одно сравнение поправку не переживает (Bonferroni-эквиваленты .36 и .43). Остальные восемь p для этого вывода не нужны. Вместе с потолком мощности (.0625 при пяти кластерах, §5.2) это означает, что подтверждающего статистического статуса у эффекта нет ни на уровне вопросов, ни на уровне проектов.

Что именно предзарегистрировано. Endpoint matched-HyDE-сравнения зафиксирован до получения любых исходов, но сам срез — нет. Предварительная фиксация анализа не защищает от selection среза, поэтому registration здесь покрывает только вторую половину процедуры. Мы читаем temporal-результат как hypothesis-generating: он сформулирован достаточно узко, чтобы независимая конфигурационная репликация могла его опровергнуть, и мы не предъявляем его как подтверждённый эффект.

7.3 Конвертируется ли выигрыш в ответ: зарегистрированная проверка

Объяснение, которое видит только тот срез, на котором найдено, не может оказаться неверным. Поэтому мы зарегистрировали предсказание до расчёта: если фронт — механизм, он обязан описывать и те 2100 вопросов, где события не помогают. Протокол, правило чтения и потолки мощности зафиксированы заранее; проверка полностью офлайновая и использует пер-вопросные поля уже запечатанных прогонов, без новых генераций.

Каждый вопрос вне Temporal Duration отнесён к одной страте по тому, как изменились доставленные свидетельства при переходе Raw→Events: **A** — события доминируют (recall и precision не ниже, хотя бы одно строго выше), **B** — доминирует Raw, **C** — смешанный случай или равенство. Предсказание: дельта ассигасу положительна в A, отрицательна в B и неотличима от нуля в C.

Страта	n	Δ асс	95% ДИ	выигр./проигр.	McNemar
A (события доминируют)	650	+0, 77	[-1, 85; +3, 54]	41/36	.649
B (Raw доминирует)	209	-2, 39	[-6, 70; +2, 39]	9/14	.405
C (смешанный)	1241	-0, 24	[-1, 53; +1, 05]	32/35	.807

Таблица 6: Конфирматорная проверка на 2100 вопросах вне discovery-среза, Events—Raw, проценты и п.п.

Предсказание не подтвердилось. В страте A, где события доставляют строго лучшие свидетельства, прирост составляет лишь +0, 77 п.п. при $p = .649$. Направление в B отрицательно, как и предсказано, и C действительно содержит ноль, но главное условие правила чтения не выполнено. На уровне категорий знак дельты совпадает с направлением доминирования в 1 случае из 5 ($p = .375$).

Категориальная корреляция, в отличие от стратификации, оказалась *метрико-зависимой*, и мы приводим это как есть. Корреляция между приростом evidence F1 и приростом ассигасу по восьми категориям равна $\rho = -0, 07$ ($p = .87$), но та же корреляция, посчитанная по приросту evidence precision, равна $\rho = +0, 63$ по девяти категориям ($p = .07$) и $\rho = +0, 57$ по восьми без discovery-среза ($p = .14$). При $n = 9$ критическое значение равно 0, 68, поэтому ни одна из величин не разрешена, и выбор между ними нельзя сделать по данным: F1 смешивает recall и precision, которые у Events и Episodes движутся по-разному (§7.1). Мы поэтому не утверждаем, что связь на уровне категорий отсутствует, — мы утверждаем, что она не разрешается на девяти точках, тогда как предзарегистрированный стратифицированный тест на 2100 вопросах её не подтверждает. Вывод работы опирается на второе, а не на первое.

Чего проверка *не* показывает. Дискордантных пар мало — 77 в страте A, 23 в B, 67 в C, — потому что смена контекста редко переворачивает ответ. При 77 парах минимально детектируемый эффект в A составляет $\approx 2, 9$ п.п., так что результат исключает крупный эффект, но не разрешает малый. Это отсутствие подтверждения, а не доказанный ноль.

Вывод принимается по записанному заранее правилу: фронт — остаётся описанием discovery-среза и лишается статуса объяснения. Улучшение доставленных свидетельств само по себе не влечёт улучшения ответа, и почему события выигрывают именно на Temporal Duration, остаётся неизвестным.

Вместе с §7.1 это даёт главный результат работы, и он двусторонний. Выигрыш в доставке свидетельств реален, велик по статистическим меркам и воспроизводится; выигрыша в ответе нет, и связь

между ними не подтверждена прямой проверкой. Мы называем это *диссоциацией*: в многосторонней разговорной памяти с сильным dense raw-baseline качество retrieval перестаёт быть связывающим ограничением задолго до того, как оно становится хорошим. Обе половины измерены на одних и тех же запечатанных прогонах, поэтому асимметрия статуса здесь не риторическая: подтверждено то, что легче измерить, а не то, что удобнее для метода.

7.4 Что дают эпизоды сверх событий

Новые симметричные контроли снимают преимущество linking: Episodes chrono 18,3%, Events chrono 19,3%; разница $-1,0$ п.п., ДИ $[-5, 0; +3, 33]$, $p = .755$. В ранее запечатанном сравнении ranked episodes 20,0% против events chrono 19,3% разница составляла лишь $+0,67$ п.п., $p = .888$.

Отдельно отметим несогласованность, которую мы не объясняем: хронологический порядок помогает Raw (+1, 7 п.п.) и Events (+2, 3 п.п.), но для Episodes он вреден ($20,0 \rightarrow 18,3$). Все три сдвига — единицы вопросов на $n = 300$, и мы не считаем их различимыми; это скорее оценка масштаба шума, чем три разных эффекта.

Это важный отрицательный результат. Версионная цепочка полезна для инспекции и может соединить конкретные изменения, но её средний вклад в retrieval не отделяется от набора отдельных events. Хороший поиск способен пережить false split, независимо доставив обе записи, поэтому усложнение linker не обязано улучшать endpoint.

8 Эффективность и инженерные свойства

8.1 Стоимость и задержка

Полный EverMemBench эксперимент зарегистрировал 26 413 API calls и верхнюю оценку list-price \$8,88. Из них построение памяти gpt-4o-mini стоит \$4,76, embeddings — \$0,46, ответы — \$3,12, judge — \$0,55. Эти цифры относятся к исследовательскому прогону с кэшами и не равны production TCO.

Сериализованный episode snapshot занимает 12,77 MB, но полный operational run вместе с embedding-кэшем — около 2,2 GB; поэтому называть всю систему «12,8 MB» некорректно.¹

Система	Accuracy, %	Ingestion, \$/domain	Storage, GB
Hindsight	40,4	32,10	4,25
Raw (ours)	34,7	0,23	0,37
HippoRAG	33,3	8,64	5,76
Episodes (ours)	32,3	1,92	0,41
A-Mem	29,2	26,13	6,60
MemGPT	19,1	0,43	0,69
Mem0	15,5	18,41	0,99
GraphRAG	12,2	12,51	3,00

Таблица 7: Явные значения для рис. 7. Accuracy измерена на общих 606 QA GroupMemBench; ingestion cost и storage взяты из соответствующих benchmark reports. Наши accuracy пересчитаны после targeted repair; стоимость repair ответов не включена в ingestion. Backend, harness и определения storage различаются, поэтому сравнение является описательным.

На этой общей выборке Hindsight достигает 40,4% при reported ingestion \$32,10/domain и 4,25 GB; HippoRAG — 33,3%, \$8,64 и 5,76 GB; наш Raw — 34,7%, \$0,23 и 0,37 GB; Episodes — 32,3%, \$1,92 и 0,41 GB. Система экономична относительно тяжёлых структурных решений, но Hindsight точнее. Из-за разных harness-компонентов это контекст, а не контролируемая причинная оценка цены.

¹Средняя локальная retrieval latency растёт $11,59 \rightarrow 13,70$ мс (p95 $12,70 \rightarrow 15,04$ мс); это только ranking, без сети, extraction, generator и judge.




Рис. 7: Описательный GroupMemBench efficiency landscape на общей выборке 606 QA по значениям benchmark paper и нашего adapter. Размер точки кодирует reported storage. Наши точки используют repaired amendment; определения стоимости и backend различаются, поэтому график показывает инженерный trade-off, но не поддерживает claim «дешевле при том же качестве».

8.2 Воспроизводимость как часть метода

Memory construction завершается до чтения QA; snapshots и input manifests запечатываются SHA-256. Вызовы к модели кэшируются по содержимому и версии prompt/schema. При остановке процесс продолжает с последней готовой единицы. Derived records проходят повторную source-ID проверку; эксперименты A/B2 выполнялись над одной замороженной памятью без повторной extraction.

Эти детали не улучшают benchmark score напрямую, но защищают главный claim от oracle leakage и позволяют отличить изменение метода от повторного sampling.

9 Анализ ошибок

Пропуск extraction. Если событие не создано, система сводится к Raw. Forced structured output существенно повышает recall относительно добровольного tool-calling, но не гарантирует полноту.

Attribution и semantic overreach. Буквально существующая цитата может поддерживать только часть описания; пересказ может принять автора сообщения за владельца мнения. Поэтому 100% quote-validity означает целостность адреса, а не 100% корректных фактов.

False split и false merge. Свободные subject/facet формулировки раскалывают одну линию на несколько эпизодов. Retrieval часто переживает split, находя обе записи. Merge опаснее: он приносит нерелевантный контекст во все будущие обращения. Консервативный resolver закономерно предпочитает NEW, что снижает длину цепочек, но защищает precision.

Context displacement. Derived hit занимает место в top- k и иногда вытесняет полезный raw turn. Это правдоподобное объяснение нейтрального/отрицательного переноса вне temporal slice и особенно в speaker-conditioned GroupMemBench.

10 Ограничения

Главный *mechanism result* найден *post hoc*; все его контроли используют те же 300 вопросов и не являются независимой репликацией. После Holm-поправки на девять официальных категорий он не значим ($\alpha/9 = .0056$ против номинальных $.0402$ и $.0479$), а пять Ever projects не позволяют получить значимость на уровне кластеров ни при каком исходе (минимальный достижимый $p = .0625$). При этом endpoint, у которого априорно зафиксированы и срез, и анализ (Group primary), отрицателен. Положительный вывод работы поэтому остаётся hypothesis-generating и требует конфирматорной репликации на независимом срезе. Общая ассигасу остаётся около 50%, temporal — ниже 20%.

Симметрично ограничим и подтверждённый результат. Evidence-метрика измеряет *доставку*, а не пользу: gold anchor в контексте не означает, что генератор его использовал, а рост precision не означает семантической верности derived-текста. Абсолютная величина скромна — +0, 117 gold-попадания на вопрос, — и базовый recall 8,1% означает, что более 90% золотых свидетельств не достаёт ни одно из условий; мы двигаем малую долю малой доли. Наконец, gold anchors выпущены бенчмарком, и все выводы наследуют их полноту.

Отдельно ограничим null. Память строится дешёвым экстрактором (gpt-4o-mini), поэтому вывод «универсального event gain нет» справедлив для этого качества извлечения, а верхняя граница при сильном экстракторе не измерена. Сэр «не более двух событий на turn» и веса 0,6/0,4 в $S(e, E)$ выбраны априорно и не абларованы. Фронтир-объяснение не переживает собственную конфирматорную проверку (§7.3), так что наблюдаемое преимущество на Temporal Duration остаётся без механизма.

Source pointer валиден механически, но полный human-аудит entailment не завершён. Review sheets существуют, однако не размечены полностью и не используются как опубликованная метрика. HyDE-контроль завершён, но использует те же 300 exploratory-вопросов и не является независимой репликацией. Targeted GroupMemBench amendment восстановил все 102 первоначально пустых output без изменения остальных 1388 ответов и verdicts. Он остаётся post-protocol анализом, а не официальной leaderboard submission. При параллельном заполнении repair-cache один общий payload был вызван дважды из-за отсутствия межпроцессной блокировки; извлечённые финальные ответы совпали, и дубликат не изменил ни одну метрику. Стоимость зависит от цен на 12 сентября 2026 г., кэшей и выбранных API; latency измерена локально.

Evidence-метрики не вычислялись для GroupMemBench: раннер сохранял только verdict. Это единственный набор с устойчивым отрицательным переносом, поэтому именно там диссоциацию стоило бы проверить в третий раз, и именно там мы её не проверили. Расчёт офлайновый и не требует новых генераций — раскрытые source IDs по обоим условиям уже запечатаны, — но на момент письма он не выполнен, и гипотеза вытеснения из §9 остаётся непроверенной.

Наконец, метод не предлагает новую foundation model и не решает open-domain или multimodal memory. Он предполагает bounded conversation network и стабильные идентификаторы участников; upstream transcription и identity resolution вне центральной оценки.

11 Заключение

Мы исследовали простой инвариант: производная память должна помогать искать, не подменяя собой доказательство. Elem хранит самостоятельное event representation вместе с неизменяемыми адресами raw turns, ранжирует raw и derived документы в одном пуле и раскрывает найденную память обратно в speaker- и time-grounded evidence.

Первая половина инварианта выполняется, и это измерено надёжнее всего остального в работе. События улучшают доставку свидетельств на всех 2400 вопросах (+3, 21 п.п. precision при +0, 64 п.п. recall), доставляя при этом меньше текста, а не больше; эффект положителен во всех девяти категориях, воспроизводится на SocialMemBench и доминирует matched HyDE. Измерено это детерминированной метрикой, не зависящей ни от генератора, ни от judge.

Вторая половина не выполняется. Ни один из этих выигрышей не переходит в качество ответа: на всех вопросах ассигасу не двигается, а зарегистрированная проверка на 2100 вопросах вне discovery-

среза связь между улучшением свидетельств и улучшением ответа не подтверждает. Единственный номинально значимый прирост ассигасы найден post hoc и не переживает поправку; endpoint, у которого априорно зафиксированы и срез, и анализ, отрицателен. Social переносится нейтрально, Group — отрицательно даже после targeted repair.

Мы считаем эту диссоциацию основным результатом, а не неудачей. Она означает, что в много-сторонней разговорной памяти с сильным dense raw-baseline улучшение retrieval перестаёт окупаться раньше, чем retrieval становится хорошим: при базовом recall 8% узкое место уже не там. Практическое следствие для инженера прямое — *сначала сохранять свидетельство, затем строить над ним поисковую абстракцию*: адресуемость обходится почти бесплатно (\$1,92 за домен, 0,41 GB, +2 мс) и выживает при ошибках derived-слоя, но закладывать в план прирост ассигасы от неё на сегодняшних бенчмарках не следует. Следствие для исследователя — что измерять: ассигасы на этих размерах выборки не разрешает эффекты, которые evidence-эндпоинт разрешает с запасом в десятки порядков, и работа, отчитывающаяся только по ассигасы, с высокой вероятностью не увидит ни своего эффекта, ни его отсутствия.

Список литературы

- Tong Chen, Hongwei Wang, Sihao Chen, Wenhao Yu, Kaixin Ma, Xinran Zhao, Hongming Zhang, and Dong Yu. Dense X retrieval: What retrieval granularity should we use? *arXiv:2312.06648*, 2023. URL <https://arxiv.org/abs/2312.06648>.
- Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready ai agents with scalable long-term memory. *arXiv:2504.19413*, 2025. URL <https://arxiv.org/abs/2504.19413>.
- Luyu Gao, Xueguang Ma, Jimmy Lin, and Jamie Callan. Precise zero-shot dense retrieval without relevance labels. In *Proceedings of ACL*, 2023a. URL <https://aclanthology.org/2023.acl-long.99/>.
- Tianyu Gao, Howard Yen, Jiatong Yu, and Danqi Chen. Enabling large language models to generate text with citations. *arXiv:2305.14627*, 2023b. URL <https://arxiv.org/abs/2305.14627>.
- Bernal Jiménez Gutiérrez, Yiheng Shu, Yu Gu, Michihiro Yoon, et al. HippoRAG: Neurobiologically inspired long-term memory for large language models. *arXiv:2405.14831*, 2024. URL <https://arxiv.org/abs/2405.14831>.
- Chuanrui Hu, Tong Li, Xingze Gao, Hongda Chen, Yi Bai, Dannong Xu, Tianwei Lin, Xiaohong Li, Yunyun Han, Jian Pei, and Yafeng Deng. Evaluating long-horizon memory for multi-party collaborative dialogues. *arXiv:2602.01313*, 2026. URL <https://arxiv.org/abs/2602.01313>.
- Chris Latimer, Nicolò Boschi, Andrew Neeser, Chris Bartholomew, Gaurav Srivastava, Xuan Wang, and Naren Ramakrishnan. Hindsight is 20/20: Building agent memory that retains, recalls, and reflects. *arXiv:2512.12818*, 2025. URL <https://arxiv.org/abs/2512.12818>.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL <https://arxiv.org/abs/2005.11401>.
- Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of LLM agents. *arXiv:2402.17753*, 2024. URL <https://arxiv.org/abs/2402.17753>.
- Olukunle Owolabi. SocialMemBench: Are AI memory systems ready for social group settings? *arXiv:2605.17789*, 2026. URL <https://arxiv.org/abs/2605.17789>.

- Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. MemGPT: Towards LLMs as operating systems. *arXiv:2310.08560*, 2023. URL <https://arxiv.org/abs/2310.08560>.
- Joon Sung Park, Joseph C. O’Brien, Carrie J. Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative agents: Interactive simulacra of human behavior. *arXiv:2304.03442*, 2023. URL <https://arxiv.org/abs/2304.03442>.
- Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A temporal knowledge graph architecture for agent memory. *arXiv:2501.13956*, 2025. URL <https://arxiv.org/abs/2501.13956>.
- Parth Sarthi, Salman Abdullah, Aditi Tuli, Shubh Khanna, Anna Goldie, and Christopher D. Manning. RAPTOR: Recursive abstractive processing for tree-organized retrieval. In *International Conference on Learning Representations (ICLR)*, 2024. URL <https://arxiv.org/abs/2401.18059>.
- Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. LongMemEval: Benchmarking chat assistants on long-term interactive memory. *arXiv:2410.10813*, 2024. URL <https://arxiv.org/abs/2410.10813>.
- Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. A-MEM: Agentic memory for llm agents. *arXiv:2502.12110*, 2025. URL <https://arxiv.org/abs/2502.12110>.
- Jingbo Yang, Kwei-Herng Lai, Xiaowen Wang, Shiyu Chang, Yaar Harari, and Evgeniy Gabrilovich. GroupMemBench: Benchmarking LLM agent memory in multi-party conversations. *arXiv:2605.14498*, 2026. URL <https://arxiv.org/abs/2605.14498>.

А Полные разрезы EverMemBench

Тип	n	RAW	EVENTS	EPISODES
Constraint	402	79,9	79,1	79,6
Multi-hop	249	12,9	13,3	13,3
Proactivity	427	65,8	64,6	64,2
Single-hop	213	89,7	89,7	87,8
Skill	169	33,7	32,0	30,8
Style	176	30,1	33,5	38,1
Temporal Duration	300	12,3	16,3	20,0
Title	196	46,4	45,9	43,4
Update	268	46,3	47,0	47,4

Таблица 8: Accurasy по всем официальным категориям, проценты. EVENTS здесь — полный experiment A без token/order controls.

В Доставка свидетельств по категориям

Тип	n	Δ precision	95% ДИ
Single-hop	213	+8, 28	[+6, 50; +10, 12]
Temporal Duration	300	+7, 51	[+5, 92; +9, 11]
Style	176	+6, 31	[+4, 82; +7, 84]
Update	268	+3, 24	[+2, 12; +4, 39]
Skill	169	+2, 32	[+1, 04; +3, 73]
Multi-hop	249	+1, 63	[+0, 59; +2, 67]
Title	196	+1, 55	[+0, 85; +2, 30]
Proactivity	427	+1, 13	[+0, 77; +1, 52]
Constraint	402	+0, 30	[-0, 07; +0, 69]

Таблица 9: Events—Raw, парная разница evidence precision по девяти официальным категориям EverMemBench, проценты и п.п. Знак положителен везде; ДИ исключает ноль в восьми категориях из девяти. Сравните с таблицей 8: категория с наибольшим приростом доставки (Single-hop) показывает падение ассурасу, поскольку ассурасу там у потолка.

С Точная спецификация хранения

Единица	Поля и назначение
RawTurn	ID, conversation network, speaker, timestamp, text; неизменяемый адрес.
MemoryEvent	ID, index text, type, viewpoint owner, subject, temporal mode, observed time, evidence, local context.
EventEvidence	Event ID, raw source ID, literal quote; проверяемая связь.
EpisodeEvent	Episode ID, Event ID, order, attach operation; append-only история.
SearchDocument	kind, index text, render text, source IDs; общий retrieval interface.

Таблица 10: Логическая схема не зависит от JSONL, SQLite или PostgreSQL backend.

Д Артефакты и границы утверждений

Код, протоколы и конфигурации: <https://github.com/yaroslavlikh/temporal-episodes> (репозиторий закрыт до публикации). Что именно он распространяет, определяется лицензией каждого

бенчмарк: пер-вопросные предсказания и вердикты для EverMemBench (данные под Apache 2.0) и SocialMemBench (CC BY 4.0), а для GroupMemBench, у которого лицензии нет, — только агрегаты и SHA-256 удержанных пер-вопросных файлов. Кэши моделей, эмбединги и сами корпуса не распространяются. Идентификаторы и хэши запечатанных прогонов перечислены ниже.

Основные immutable каталоги:

- evermembench_temporal_episodes_official_v1_20260915_021550_MSK;
- final_sprint_A_events_full_v1_20260915_233142_MSK;
- final_sprint_B2_episodes_chrono_v1_20260915_232910_MSK;
- final_sprint_C_hyde_raw_v1_20260916_024144_MSK;
- final_sprint_C2_hyde_token_matched_v1_20260916_024306_MSK;
- socialmembench_temporal_episodes_official_harness_v1_20260912_122626_MSK.

Дополнительный sealed amendment GroupMemBench хранится в final_sprint_D_groupmembench_repair_v2: 1490 строк, results_v2 SHA-256 41ae844eabb292f9d0c7edbeed0476981155340ac85c5ef197d2184fcbd0d4a5, predictions_v2 SHA-256 20f2c60180a58d37c63f96904896266c8ac5805f83d822d321a34926850c8a96. Каталог не копировался в отдельный frozen container; восемь исходных файлов проверены по manifest и не изменены. И использованные revisions: EverMemBench code e10b3d52f0e4, data a6b210a32248; GroupMemBench e2682e01ff49. Скрипт фигур хэширует входные summaries/reports. Публичное размещение кода не означает автоматического разрешения на перераспространение benchmark corpora.

Какой Social-прогон канонический. В артефактах присутствуют два SocialMemBench-пайплайна, и смешивать их нельзя. Канонический — socialmembench_temporal_episodes_official_harness_v1: text-embedding-3-small, один cosine top-10 на условие, идентичный code path для answer/judge/packing; из него взяты все числа работы, а строки RAW/FLAT/VERSIONED в нём — неизменённые результаты замороженного прогона 2026-09-11. Второй, socialmembench_temporal_episodes_full_v1, — более ранний гибрид (локальная MiniLM, raw top-12 + episode top-12, бюджет 400 слов); его Raw даёт evidence recall 48,5% против 67,5% у канонического. Парное сравнение условия из одного прогона с Raw из другого даёт правдоподобные и полностью ложные числа; мы отмечаем это здесь, потому что оба каталога распространяются вместе.

Пересчёт evidence-эндпоинта. Все парные числа §7.1 и приложения 9 воспроизводятся офлайн скриптом research/evidence_endpoint_analysis.py, который читает только запечатанные прогоны, не делает вызовов API и пишет research/figures/evidence_endpoint_results.json; манускрипт берёт числа оттуда. В публичном репозитории те же величины вместе с зарегистрированной проверкой фронта из §7.3 пересчитываются из опубликованных пер-вопросных файлов скриптом analysis/verify_evidence_endpoint.py, который сверяет каждую с напечатанной здесь и падает при любом расхождении.

Допустимые формулировки. Можно говорить о конкурентоспособности полной системы в adapter evaluation, о подтверждённом улучшении *доставки свидетельств* на всём наборе и его репликации на SocialMemBench, о доминировании над matched HyDE по плотности доставленного evidence, о номинальном temporal signal в accuracy и о provenance как адресуемости источника. Нельзя называть результат официальным SOTA, доказанным universal gain, семантически верифицированными фактами или доказанной пользой episode linking. Нельзя также утверждать, что события выигрывают *потому что* улучшают recall-precision фронтир доставленных свидетельств: зарегистрированная проверка этого не подтвердила (§7.3). Нельзя переносить подтверждённый результат по доставке на качество ответа: это ровно та импликация, которую работа проверяет и не подтверждает. Нельзя называть улучшение precision семантической верностью derived-текста и нельзя распространять его на GroupMemBench, где evidence-метрики не считались.